Електротехнички факултет

Универзитет у Београду

Катедра за сигнале и системе

Дипломски рад

Реконструкција 3D облика на основу једне слике употребом дубоког учења

Кандидат

Леа Ирт

бр. индекса 2022/0371

Ментор

проф. др Горан Квашчев

редовни професор

Београд, јул 2026. године

Резиме рада

У овом дипломском раду разматра се реконструкција 3D облика на основу једне фронталне RGB слике применом дубоког учења. Уместо да се 3D облик одреди директно из улазне слике, сложен поступак реконструкције у овом раду разложен је на две повезане фазе. У првој фази се из улазне слике предвиђају нормална и дубинска мапа, које описују геометрију видљивих површина објекта, док се у другој фази из издвојених геометријских обележја формира коначан 3D модел. Поред тога, у раду је испитана и варијанта у којој се латентни вектор предвиђа директно из оригиналне слике, без издвајања геометријских обележја.

Систем је обучаван и тестиран на синтетички генерисаном скупу података за једну јасно дефинисану класу објеката. Таква поставка, заједно са разлагањем поступка реконструкције на више корака, омогућила је контролисано праћење резултата кроз читав рад.

Главно питање на које рад покушава да да одговор јесте колико избор улазних информација утиче на квалитет реконструкције. Разматрају се три приступа, реконструкција без издвојених геометријских обележја, реконструкција заснована на једном обележју и реконструкција која комбинује више геометријских обележја. Резултати показују да коришћење геометријских обележја даје боље резултате него без њих, али је та разлика незнатна.

Захвалница

Захваљујем се свом ментору, проф. др Горану Квашчеву, на саветима, смерницама и брзим и конструктивним одговорима на сва моја питања током израде овог дипломског рада.

Посебну захвалност дугујем свом тати на помоћи, идејама, активном праћењу напретка мог рада и дискусијама кроз које сам лакше сагледала шта би све било интересантно испробати и унапредити.

Хвала и мојој породици и пријатељима на љубави и подршци током студија.

Леа Ирт
У Београду, јул 2026. године

Садржај

Резиме рада **1**

Захвалница **2**

1 Увод **5**
1.1 Проблем и циљ рада . . . 5
1.2 Мотивација . . . 6
1.3 Ограничења рада . . . 6
1.4 Структура рада . . . 7

2 Теоријске основе **8**
2.1 3D репрезентације . . . 8
2.1.1 SDF репрезентација . . . 8
2.1.2 Mesh репрезентација . . . 9
2.1.3 Marching Cubes алгоритам . . . 9
2.1.4 Ray casting . . . 10
2.1.5 Bounding Volume Hierarchy (BVH) . . . 12
2.2 2.5D репрезентације . . . 13
2.2.1 Нормална мапа . . . 13
2.2.2 Дубинска мапа . . . 14
2.3 Модели . . . 15
2.3.1 U-Net . . . 15
2.3.2 DeepSDF . . . 16
2.3.3 ResNet . . . 16
2.4 Метрике и евалуација . . . 17
2.4.1 Chamfer растојање . . . 17
2.4.2 Средња апсолутна грешка (MAE) . . . 17
2.4.3 Корен средње квадратне грешке (RMSE) . . . 17
2.4.4 Косинусна компонента . . . 18

3 Скуп података **19**
3.1 Избор скупа података . . . 19
3.2 Припрема 3D модела . . . 19
3.3 Генерисање улазних слика . . . 20
3.4 Генерисање референтних нормалних мапа . . . 21
3.5 Генерисање референтних дубинских мапа . . . 22
3.6 Генерисање SDF узорака . . . 23

4 Методологија рада **24**
4.1 Преглед система 24
4.2 Прва фаза (од 2D до 2.5D) 24
4.2.1 Предикција нормалне мапе 24
4.2.2 Предикција дубинске мапе 26
4.3 Друга фаза (од 2.5D до 3D) 27
4.3.1 Улаз друге фазе 27
4.3.2 Ауто-декодер и латентни простор (Stage A) 27
4.3.3 Енкодер за предикцију латентног вектора (Stage B) 29
4.3.4 Реконструкција mesh модела 30
4.4 Ток обучавања 30
4.5 Параметри обучавања 30
4.6 Реконструкција 3D модела 31
4.7 Имплементација 31

5 Резултати **33**
5.1 Резултати предикције нормалних мапа 33
5.2 Резултати предикције дубинских мапа 35
5.3 Резултати обучавања ауто-декодера (Stage A) 37
5.4 Резултати обучавања енкодера (Stage B) 38
5.5 Финална 3D реконструкција 39
5.6 Упоредна анализа 41
5.7 Анализа неуспешних примера 42

6 Дискусија **43**
6.1 Узроци неуспешних примера 44
6.2 Ограничења и правци даљег рада 44

7 Закључак **46**

8 Литература **47**

1 Увод

Рачунарска визија је област рачунарске науке која се бави аутоматским разумевањем и интерпретацијом визуелног садржаја. Она омогућава рачунарима да у реалном времену обрађују слике, видео-записе и снимке, препознају њихов садржај и издвајају смислене информације. Последњих десетак година ова област се све више ослања на методе машинског и дубоког учења. Рачунарски системи данас препознају објекте на сликама, издвајају их из позадине, процењују дубину сцене, али и генеришу потпуно нов визуелни садржај. Употреба неуралних мрежа и дубоког учења омогућила је решавање много сложенијих проблема и тиме додатно проширила спектар задатака којима се рачунарска визија данас бави.

Један од популарних задатака савремене рачунарске визије јесте реконструкција 3D облика на основу ограниченог броја 2D слика. Овај задатак је захтеван јер сваки приказ садржи само део информација о облику посматраног објекта, док стварна дубина, геометрија и делови који на сликама нису видљиви морају бити процењени. Исти скуп улазних слика може одговарати различитим просторним облицима, због чега оваква реконструкција није једнозначна. Модел зато мора да на основу ограничених визуелних информација формира представу о томе како би објекат могао да изгледа у простору.

Овај проблем може се решавати различитим приступима, у зависности од поставке задатка и усвојених претпоставки. У наставку ће бити приказана једна поједностављена варијанта решавања проблема реконструкције 3D облика на основу једне слике, у оквиру једне категорије објеката.

1.1 Проблем и циљ рада

Полазни проблем овог рада јесте реконструкција 3D облика софе на основу једне фронталне RGB слике резолуције $256 \times 256 \times 3$. Коначан резултат реконструкције је 3D mesh модел, односно површинска мрежа која описује просторни облик објекта. У оквиру овако постављеног задатка потребно је, на основу доступног сликовног приказа, проценити просторну структуру софе.

Циљ рада је имплементација и анализа поступка реконструкције 3D облика на основу једне слике, ограниченог на посматрану врсту објеката. Основна идеја је да се сложен проблем реконструкције подели на две повезане фазе, чиме се омогућава јасније праћење и анализа међурезултата. На тај начин могуће је прецизније сагледати како поједини делови система утичу на коначан резултат.

Централно питање којим ће се рад бавити јесте да ли се бољи резултати добијају када се из слике издваја само једно геометријско обележје или када се комбинују два различита обележја. У том смислу, пореде се три приступа, реконструкција без

издвојених геометријских обележја, реконструкција заснована на једном обележју и реконструкција која користи комбинацију два обележја. Циљ овог поређења је да покаже у којој мери издвајање геометријских информација из улазне слике доприноси квалитету коначне реконструкције.

Практична вредност рада огледа се и у томе што ће финални mesh модел моћи да се увезе у Blender или други популаран алат за приказ и уређивање 3D модела, чиме се оставља простор и за његову даљу практичну употребу.

1.2 Мотивација

Тродимензионална реконструкција има примену у бројним областима, као што су роботика, проширена и виртуелна реалност, дигитализација објеката, индустријски дизајн, архитектура, медицина, електронска трговина, индустрија видео-игара и др. У контексту намештаја, 3D модел добијен на основу слике може бити користан за визуелизацију производа, виртуелно постављање објеката у простор, израду дигиталних каталога или употребу модела у виртуелним и интерактивним окружењима.

Посебна вредност реконструкције из једне слике огледа се у једноставности улаза. За разлику од метода које захтевају више фотографија, специјализоване камере или 3D сензоре, једна RGB слика може се добити обичном камером, издвојити из каталога или преузети из постојеће архиве. Управо та доступност улаза чини овај задатак посебно значајним за практичну примену.

1.3 Ограничења рада

Рад је ограничен на једну класу објеката, односно на софе. Овакво ограничење омогућава да се проблем јасније дефинише и да се једна категорија облика детаљније анализира. Уз то, коришћене су синтетички генерисане слике, па добијени резултати не морају у потпуности да се пренесу на реалне фотографије, које могу садржати сложенију позадину, шум, различите услове осветљења, перспективна изобличења и делимично заклоњене објекте.

У овој верзији система нису обухваћене ни значајније разлике у текстури, боји и материјалу софе. Све слике генерисане су на основу једноставних, нетекстурисаних 3D модела, са неутралним сивкасто-белим изгледом површине. Због тога исти 3D облик на RGB слици у раду није посматран кроз разлике које у пракси могу настати услед различитих материјала, текстура и начина на који површина рефлектује светлост. Увођење таквих варијација остаје један од праваца даљег развоја система.

1.4 Структура рада

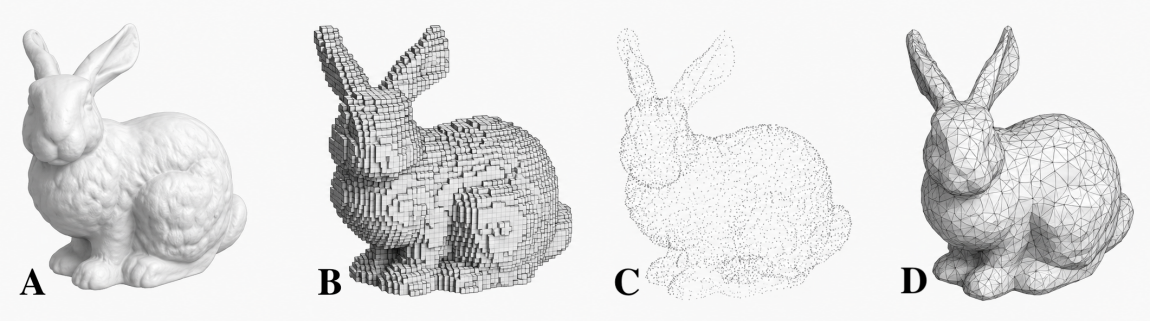
Рад је организован у седам поглавља. Након увода, у другом поглављу биће приказане теоријске основе потребне за разумевање проблема. Треће поглавље биће посвећено коришћеном скупу података и поступку његове припреме. У четвртом поглављу биће представљена методологија рада, укључујући имплементацију, обучавање модела, параметре обучавања и критеријуме евалуације. У петом поглављу биће приказани добијени резултати, у шестом ће бити дата дискусија, а у седмом закључак и могући правци даљег рада.

2 Теоријске основе

У овом поглављу приказани су и укратко појашњени неки од теоријских појмова који се даље користе у раду и који су потребни за разумевање предложеног поступка.

2.1 3D репрезентације

Тродимензионални објекат може се представити на више начина, у зависности од потребе и намене. Најчешће репрезентације су облак тачака (*Point Cloud*), voxel мрежа (*Voxel Grid*), mesh модел (*Mesh*) и имплицитна функција (*Implicit Function*). Ове репрезентације разликују се по сложености, количини меморије коју заузимају, начину записа и могућностима које пружају при приказу и обради.



Слика 1. Поређење различитих 3D репрезентација на примеру модела Stanford Bunny. A означава оригинални облик, B voxel репрезентацију, C облак тачака, а D mesh модел.

2.1.1 SDF репрезентација

SDF (*Signed Distance Function*)[6] представља једну од имплицитних 3D репрезентација објекта. Код ове репрезентације, 3D облик се дефинише функцијом S која свакој тачки простора $\mathbf{p} = (x, y, z)$ додељује вредност

$$S(\mathbf{p}) = d, \tag{1}$$

где је d растојање тачке $\mathbf{p}$ од најближе тачке на површини објекта, са предзнаком. Апсолутна вредност $|d|$ представља растојање тачке од површине објекта, док знак d показује положај тачке у односу на површину. Ако је $d < 0$, тачка се налази унутар објекта, ако је $d = 0$, тачка је баш на површини објекта, а ако је $d > 0$, тачка је изван објекта.

Површина објекта одговара нултом нивоу функције, односно скупу тачака за које важи $S(\mathbf{p}) = 0$. Облик тако није ограничен на фиксну дискретну мрежу, већ је представљен континуалном функцијом коју неуронска мрежа може да процени

у произвољној тачки простора, а којом се такође могу лако моделовати и финији детаљи објекта. Све ово чини SDF репрезентацију веома погодном за употребу у задацима реконструкције.

2.1.2 Mesh репрезентација

Mesh модел (*Mesh*) представља једну од експлицитних 3D репрезентација објекта, при чему се површина објекта описује теменима, ивицама и полигонима, најчешће троугловима. Она је погодна за приказивање, обраду и чување 3D модела, јер директно описује површину објекта, а лако се користи и у популарним алатима за рад са 3D моделима, попут Blender-a, Adobe Substance 3D-a и MeshLab-a.

2.1.3 Marching Cubes алгоритам

Marching Cubes је алгоритам који имплицитно описан 3D облик, попут SDF функције, преводи у експлицитан mesh модел, тако што из тродимензионалног скаларног поља издваја изоповрш (*isosurface*).[1] Представили су га Lorensen и Cline 1987. године[9], а и данас је један од стандардних поступака за прелазак из SDF репрезентације у троугаону мрежу.

Основна идеја алгоритма јесте да се простор подели на правилну мрежу малих коцки. Свака коцка има осам темена, а у сваком темену позната је вредност функције. На основу знака те вредности, свако теме се сврстава у једну од две групе, темена испод површине (унутрашњост објекта) или темена изнад површине (спољашњост објекта).

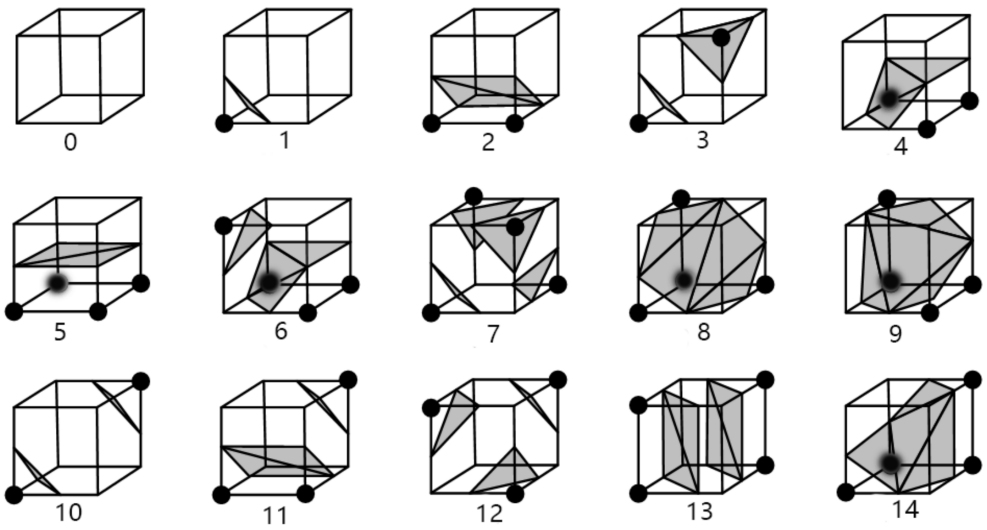
За једну коцку постоји

$$2^8 = 256 \tag{2}$$

различитих начина да се осам темена распореди у ове две групе, при чему сваки такав распоред представља једну конфигурацију те коцке. За сваку конфигурацију унапред је одређено које троуглове треба нацртати унутар коцке да би се приближно приказала површина објекта која кроз њу пролази.

Иако постоји 256 оваквих распореда, коцка је симетрична, па се сви они могу свести на свега 15 суштински различитих, основних случајева (Слика 2). Остале конфигурације добијају се из ових 15 случајева простим ротирањем коцке или заменом улоге унутрашњих и спољашњих темена.

[1] Изоповрш представља скуп свих тачака простора у којима поље има исту, задату вредност.



Слика 2. Петнаест основних тополошких конфигурација Marching Cubes алгоритма.[13] Темена означена црном тачком су темена испод површине објекта (унутрашњост), док темена без тачке представљају темена изнад површине (спољашњост). Сива површина унутар сваке коцке приказује оне троуглове које алгоритам за дату конфигурацију исцртава.

Кад ово правило применимо на све коцке у простору, на заједничкој ивици две суседне коцке увек ће важити иста ситуација, та ивица или садржи теме троугла, или га не садржи. Питање је где на ивици поставити то теме, а алгоритам то решава линеарном интерполацијом.

Нека су $\mathbf{p}_1$ и $\mathbf{p}_2$ темена исте ивице, а f_1 и f_2 вредности функције у њима. Ако f_1 и f_2 имају различит знак, површина објекта пролази кроз ту ивицу, а теме троугла поставља се ближе оном темену чија је апсолутна вредност мања, односно које је ближе површини. Положај $\mathbf{p}$ рачуна се као

$$\mathbf{p} = \mathbf{p}_1 + \frac{-f_1}{f_2 - f_1}(\mathbf{p}_2 - \mathbf{p}_1), \tag{3}$$

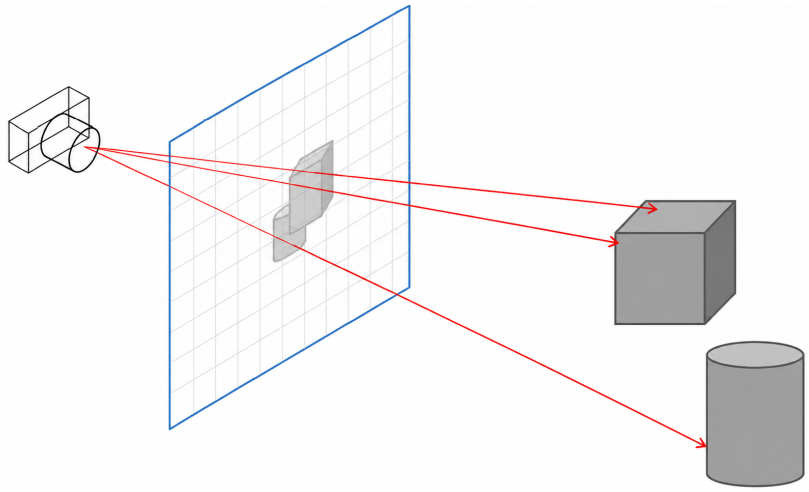
где размер $\frac{-f_1}{f_2-f_1}$ показује колико се, дуж ивице, треба померити од $\mathbf{p}_1$ ка $\mathbf{p}_2$ да би се стигло до тачке у којој је SDF функција једнака нули, односно до саме површине објекта.

Поступак се понавља за сваку коцку посебно. Две суседне коцке деле исту ивицу и иста два темена, са истим вредностима f_1 и f_2, па формула даје исту тачку пресека за обе. Троуглови из свих коцки се тако спајају у једну целовиту, непрекинуту троугаону мрежу која апроксимира површину читавог 3D објекта.

2.1.4 Ray casting

Ray casting[10] је поступак који се користи за рендеровање слике из 3D сцене, тако што за сваки пиксел одређује који део површине објекта је кроз њега видљив. Из камере се, кроз центар сваког пиксела, шаље по један зрак, а затим се проверава

коју површину у сцени тај зрак прво погоди. Та прва погођена површина одговара ономе што ће се на датом пикселу приказати на слици.



Слика 3. Илустрација поступка бацања зрака (*ray casting*). Лево је камера, а испред ње равна слика приказана као плава мрежа пиксела. Кроз центар сваког пиксела слике из камере се шаље по један зрак. Приказана су три оваква зрака, два погађају видљиве површине коцке, док трећи пролази поред коцке и погађа ваљак иза ње.

Сваки зрак се обрађује независно од осталих, па суседни пиксели на слици могу да прикажу потпуно различите објекте из сцене, у зависности од тога шта се прво нађе на путу одговарајућег зрака.

Зрак се математички описује параметарском једначином

$$\mathbf{r}(t) = \mathbf{o} + t\,\mathbf{d}, \tag{4}$$

где је $\mathbf{o}$ положај камере, $\mathbf{d}$ јединични вектор правца зрака, а $t \geq 0$ параметар који одређује колико далеко се, дуж тог правца, налази тачка $\mathbf{r}(t)$. Кад t расте од нуле, тачка $\mathbf{r}(t)$ се помера дуж зрака, почев од камере даље у сцену.

Модели су представљени троугаоном мрежом, па се тражење прве погођене површине своди на проверу пресека зрака са појединачним троугловима мреже. Тачка на троуглу описује се барицентричким координатама[2], а пресек се добија изједначавањем тачке на зраку са тачком на троуглу

$$\mathbf{o} + t\,\mathbf{d} = (1 - u - v)\,\mathbf{v}_0 + u\,\mathbf{v}_1 + v\,\mathbf{v}_2, \tag{5}$$

где су $\mathbf{v}_0$, $\mathbf{v}_1$ и $\mathbf{v}_2$ темена посматраног троугла, а u и v барицентричке координате које одређују положај тачке пресека унутар њега. Ако решење ове једначине по t, u и v задовољава услове $t > 0$, $u \geq 0$, $v \geq 0$ и $u + v \leq 1$, зрак пролази кроз тај троу-

[2]Барицентричке координате u, v и $1 - u - v$ одређују положај тачке унутар троугла у односу на његова три темена. Тачка се поклапа са одговарајућим теменом кад је његова координата једнака 1, а преостале две једнаке 0, а са тежиштем троугла кад су све три координате једнаке $\frac{1}{3}$.

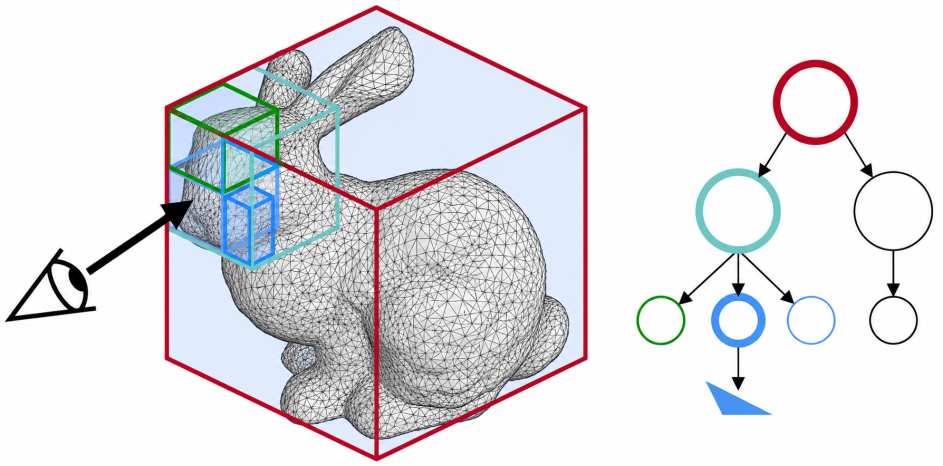
гао, у супротном га мимоилази. Директно решавање овог система захтева инверзију матрице за сваки пар зрак-троугао, што је рачунски захтевно кад мрежа има много троуглова, па се у пракси овај корак убрзава Möller–Trumbore алгоритмом, који исти резултат добија само помоћу векторских производа и сабирања.

Један зрак може пресећи више троуглова мреже, али је видљива само она површина код које пресек има најмању позитивну вредност t, јер она одговара површини најближој камери. Провера сваког зрака над сваким троуглом модела постаје спора код сложенијих модела, па се користе посебне структуре података које убрзавају претрагу, од којих је у овом контексту најважнија BVH.

2.1.5 Bounding Volume Hierarchy (BVH)

BVH (*Bounding Volume Hierarchy*)[11] је структура података која убрзава проверу пресека између зрака и 3D модела, посебно кад модел има много троуглова. Уместо да се за сваки зрак проверава пресек са сваким појединачним троуглом, група суседних троуглова се унапред обухвата једном простом фигуром, најчешће кутијом (*bounding volume*), која у себи садржи те троуглове. Иако је таква кутија већа од сваког појединачног троугла унутар ње, провера пресека између кутије и зрака је много једноставнија него провера пресека између троугла и зрака, јер је облик кутије правилнији.

Геометрија 3D модела се, дакле, дели на кутије (*bounding volumes*), а за зрак се прво проверава да ли сече кутију. Ако је не сече, сигурно не сече ниједан троугао унутар ње, па се цела та група троуглова одмах искључује из даље провере. Ако је сече, прелази се на проверу пресека са мањим кутијама унутар ње, а на крају и на проверу пресека са појединачним троугловима. На тај начин се за сваки зрак унапред искључује велики део модела, а провера пресека са појединачним троугловима врши се само тамо где је то заиста потребно.



Слика 4. Пролазак зрака кроз BVH стабло над стварном троугаоном мрежом, од кутије у корену до троугла у листу. Боје кутија лево одговарају означеном путу кроз стабло десно.

Најчешће коришћена ограничавајућа запремина је осно поравната ограничавајућа кутија (Axis-Aligned Bounding Box, AABB), чије су странице поравнате са осама координатног система, па се провера пресека између зрака и кутије своди на просто поређење координата и извршава се веома брзо. Овакве кутије се организују у бинарно стабло, од корена који обухвата цео модел до листова са малим бројем троуглова. Због тога се, за модел са N троуглова, број потребних провера по зраку своди са $O(N)$ на приближно $O(\log N)$, што чини BVH једном од стандардних структура у поступцима *ray castinga* и *ray tracing*-а.

2.2 2.5D репрезентације

Слика у RGB формату не садржи експлицитну информацију о геометрији и 3D облику објекта. Иако боја, текстура и осветљење носе корисну информацију, сами по себи не описују просторни облик. Из овог разлога се између 2D слике и 3D облика уводи 2.5D репрезентација, која је представљена у равни слике, али носи информацију о геометрији. Неке од 2.5D репрезентација су нормална мапа и дубинска мапа.

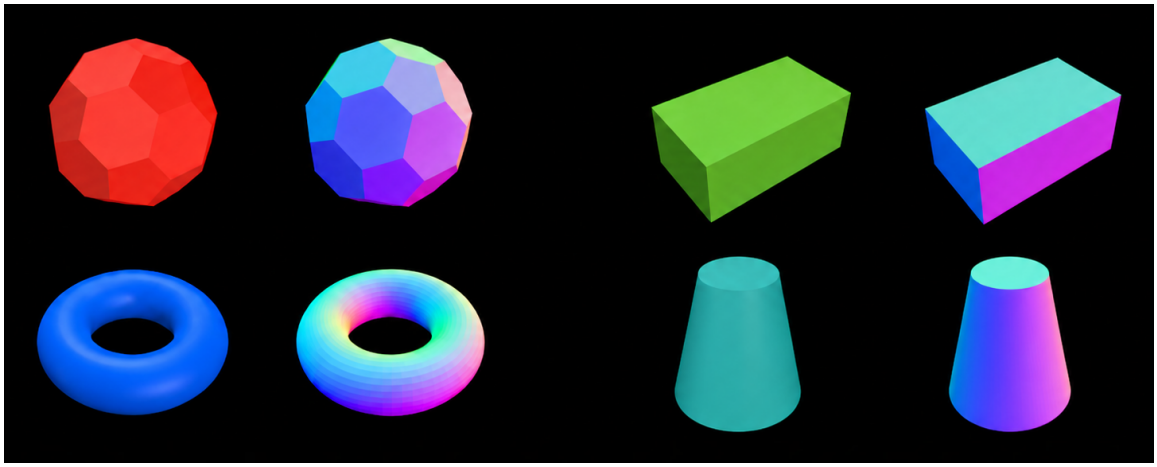
2.2.1 Нормална мапа

Нормална мапа (*Normal Map*)[1] је слика која сваком пикселу (u, v) додељује вектор нормале, односно правац у ком је окренута површина објекта у тој тачки, што се записује као

$$\mathbf{n}(u, v) = (n_x(u, v), n_y(u, v), n_z(u, v)), \tag{6}$$

где n_x, n_y и n_z показују тај правац дуж три координатне осе. Ова информација говори на коју страну и под којим углом је површина нагнута у датој тачки, што касније помаже при доношењу закључака о облику целог објекта.

При приказивању се вредности вектора нормале пресликавају у RGB боје, па нормална мапа, са по једним каналом за сваку компоненту вектора, изгледа као обична слика у боји. Те боје, ипак, не представљају стварни изглед објекта, већ само правац у ком је површина окренута.



Слика 5. Пример неколико 3D облика (лево у сваком пару) и њихових одговарајућих нормалних мапа (десно).

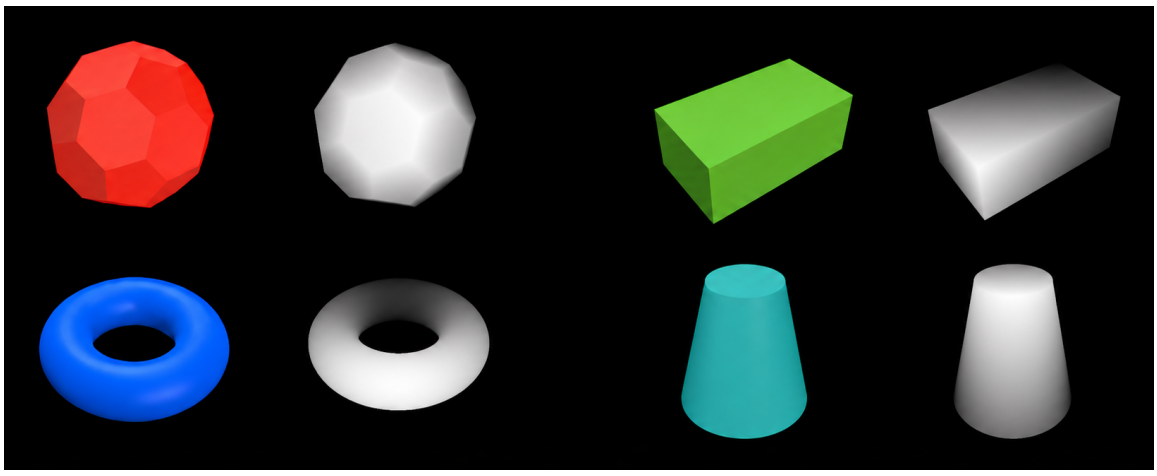
2.2.2 Дубинска мапа

Дубинска мапа (*Depth Map*)[1] је слика која сваком пикселу (u, v) додељује вредност дубине, односно колико је далеко видљива тачка површине од камере, што се записује као

$$D(u, v) = z, \tag{7}$$

где z означава ту удаљеност.

При приказивању се вредност дубине пресликава у нијансу сиве боје, па дубинска мапа, са по једним каналом за сваки пиксел, изгледа као обична црно-бела слика. Те нијансе, ипак, не представљају боју објекта, већ његову удаљеност од камере, при чему су светлије нијансе ближе камери, а тамније даље од ње.



Слика 6. Пример неколико 3D облика (лево у сваком пару) и њихових одговарајућих дубинских мапа (десно).

2.3 Модели

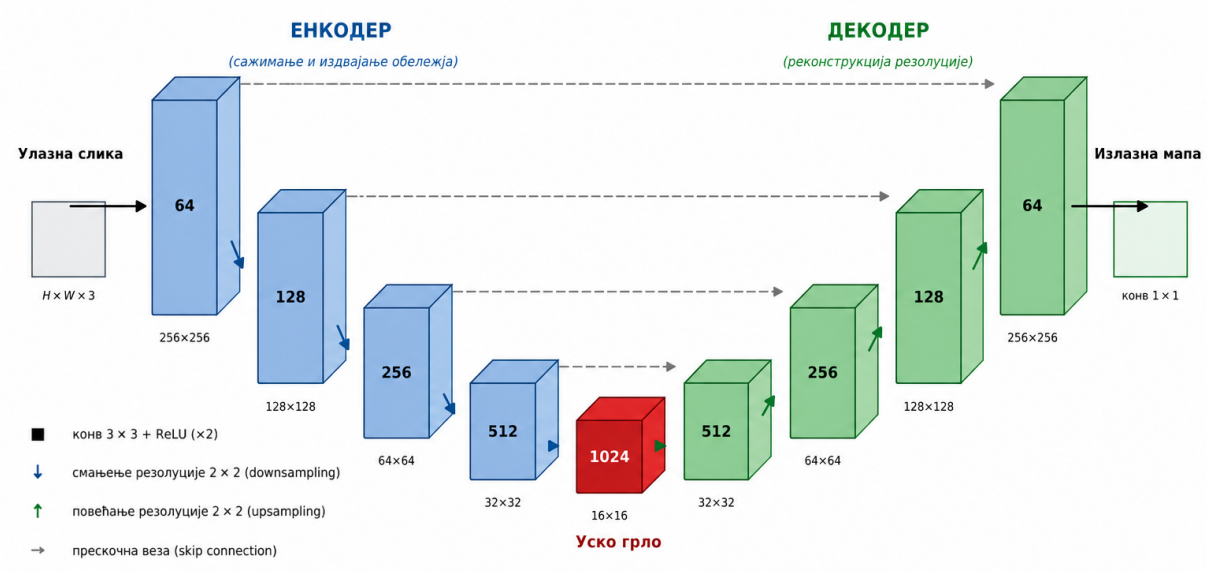
Дубоко учење је грана машинског учења заснована на обучавању дубоких неуралних мрежа, односно мрежа изграђених од наслаганих слојева неурона, где број тих слојева представља дубину мреже. Овакве мреже, на основу великог броја примера, уче како да улазне податке пресликају у жељени излаз. У обради слика посебно су значајне конволуционе неуралне мреже (CNN), које помоћу филтера који клизе преко слике прво препознају ситне детаље, попут ивица и текстуре, а затим их у дубљим слојевима спајају у сложеније описе објекта.

Поред конволуционих мрежа, значајне су и енкодер-декодер структуре, у којима један део мреже, енкодер, сажима улаз у компактнији опис, а други део, декодер, на основу тог описа реконструише излаз истих димензија као улаз.

Модели се обучавају минимизацијом функције губитка (*loss function*), која мери разлику између предвиђене и очекиване вредности. Начин на који се та разлика одређује није јединствен, већ зависи од задатка, а различити начини њеног мерења представљају различите метрике евалуације модела.

2.3.1 U-Net

U-Net[2] је енкодер-декодер архитектура за *image-to-image* задатке, у којима је излаз слика исте резолуције као улаз. Енкодер постепено смањује резолуцију и издваја све апстрактнија обележја, а декодер потом враћа резолуцију и из тих обележја реконструише излазну слику.



Слика 7. Општа структура U-Net архитектуре.

Посебна одлика U-Net архитектуре су прескочне везе (*skip connections*) између одговарајућих нивоа енкодера и декодера, које просторне детаље преносе директно

од енкодера ка декодеру, заобилазећи уско грло у средини мреже. Захваљујући овим везама, декодер поред грубе, апстрактне информације из дна мреже добија и просторне детаље сачуване у одговарајућем слоју енкодера, па излазна слика прати ивице и ситне структуре улазне слике. Ова особина чини U-Net погодном за задатке попут предикције нормалних или дубинских мапа, где је прецизност на нивоу пиксела кључна.

2.3.2 DeepSDF

DeepSDF[6] је неуронална мрежа која учи да процени вредност SDF функције у произвољној тачки простора. Уместо посебне мреже за сваки облик, користи се један заједнички декодер за целу класу објеката, а сваки облик представљен је сопственим латентним вектором (*Latent Vector*).[3] Латентни вектори се не добијају енкодером, већ се уче заједно са тежинама декодера, због чега се овакав начин обучавања назива ауто-декодер (*Auto-Decoder*).

Улаз у мрежу чине координате тачке и латентни вектор облика, а излаз је процењена вредност SDF функције у тој тачки. За разлику од метода које само одређују да ли је тачка унутар или изван објекта, DeepSDF учи и њено растојање до површине, чиме добија бољи опис облика. Вредности се често ограничавају (*clamp*) на ужи опсег око површине, како би пажња мреже била усмерена на регион најважнији за реконструкцију.

2.3.3 ResNet

Како дубина неуралне мреже расте, обучавање постаје теже, јер сигнал грешке слаби током проласка кроз велики број слојева, па дубљи слојеви све спорије и теже уче. ResNet (*Residual Network*)[4] решава овај проблем тако што сваком резидуалном блоку[4] омогућава да улазни сигнал $\mathbf{x}$ пренесе директно на свој излаз, поред онога што сам научи. Излаз блока тако није само трансформација $\mathcal{F}(\mathbf{x})$ коју он учи, већ та трансформација увећана за сам улаз

$$\mathbf{y} = \mathcal{F}(\mathbf{x}) + \mathbf{x}. \tag{8}$$

Учити само одступање у односу на улаз лакше је него учити цело пресликавање испочетка, па се мреже са много слојева, захваљујући оваквим блоковима, лакше и стабилније обучавају.

[3] Латентни вектор је сажет скуп бројева који представља најважније особине неког облика, тако да мрежа може да га препозна и користи без чувања свих оригиналних детаља. Слични облици имају сличне латентне векторе.

[4] Резидуални блок је мала група слојева мреже која не мора сама да научи цео излаз, већ само разлику (резидуал) коју треба додати на улаз да би се добио излаз.

2.4 Метрике и евалуација

Метрике мере колико је предвиђена вредност блиска очекиваној, тако што упоређују ове две вредности по унапред одређеној формули. Користе се и током обучавања, за праћење напретка модела, и при коначној евалуацији, за оцену квалитета резултата. У наставку су објашњене неке од метрика које ће касније бити коришћене у раду.

2.4.1 Chamfer растојање

За поређење два 3D облика користи се Chamfer растојање (*Chamfer Distance*)[12]. Оно не пореди моделе по идентичној мрежној структури, већ са обе површине узоркује скупове тачака P (реконструкција) и Q (референца), а затим у оба смера мери њихова најмања растојања

$$\mathrm{CD}(P,Q) = \frac{1}{|P|}\sum_{p\in P}\min_{q\in Q}\|p-q\|^2 + \frac{1}{|Q|}\sum_{q\in Q}\min_{p\in P}\|q-p\|^2, \tag{9}$$

где $|P|$ и $|Q|$ означавају број тачака у сваком од скупова. Што је вредност мања, сличност 3D модела је већа. Ова метрика је посебно погодна за реконструкцију 3D облика, јер не захтева исту мрежну структуру нити исти број темена на моделима који се пореде.

2.4.2 Средња апсолутна грешка (MAE)

Средња апсолутна грешка (MAE, *Mean Absolute Error*) мери просечно апсолутно одступање референтне вредности y_i од предвиђене вредности $\hat{y}_i$, за укупно N посматраних вредности, изражено као

$$\mathrm{MAE} = \frac{1}{N}\sum_{i=1}^{N}\left|y_i - \hat{y}_i\right|. \tag{10}$$

Користи се када је важно имати јасну меру просечне грешке у истим јединицама у којима је величина предвиђана. Разлика се узима по апсолутној вредности, па се позитивна и негативна одступања не поништавају. Нижа MAE вредност означава боље предвиђање, а предност ове метрике је то што није претерано осетљива на мали број већих одступања и даје стабилну слику просечне грешке.

2.4.3 Корен средње квадратне грешке (RMSE)

Корен средње квадратне грешке (RMSE, *Root Mean Squared Error*) мери одступање референтне вредности y_i од предвиђене вредности $\hat{y}_i$, за укупно N посматраних вредности, али пре усредњавања квадрира разлике, изражено као

$$\text{RMSE} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}. \tag{11}$$

Разлике се квадрирају пре усредњавања, па RMSE јаче наглашава појединачне грешке и оштрије кажњава већа одступања него MAE. Ова особина је корисна када није довољно знати само просечну грешку, већ и колико су изражене појединачне лоше процене. Нижа вредност RMSE, као и код MAE, означава бољу тачност.

2.4.4 Косинусна компонента

Када није важно само колика је грешка, већ и да ли је смер предвиђеног вектора исправан, користи се косинусна сличност, нарочито погодна за нормалне векторе, где је оријентација површине суштинска. Она мери угао θ између референтног вектора y_i и предвиђеног вектора $\hat{y}_i$, преко њиховог скаларног производа и норми, као

$$\cos(\theta) = \frac{y_i \cdot \hat{y}_i}{\|y_i\| \, \|\hat{y}_i\|}, \tag{12}$$

где су $\|y_i\|$ и $\|\hat{y}_i\|$ норме, а $y_i \cdot \hat{y}_i$ скаларни производ та два вектора.
Вредност је у опсегу од -1 до 1, при чему вредност 1 значи потпуно поклапање смера, а мање вредности указују на веће угаоно одступање. Током обучавања се минимизује функција губитка, па се косинусна сличност обично преводи у косинусни губитак

$$\mathcal{L}_{cos} = 1 - \cos(\theta), \tag{13}$$

где је $\cos(\theta)$ косинусна сличност из претходне формуле. Овај губитак једнак је нули када су вектори потпуно усклађени, а расте са повећањем угла између њих. У комбинацији са другим компонентама, као што је MSE, овај члан омогућава да модел истовремено учи и исправан смер и прецизне нумеричке вредности.

3 Скуп података

Ово поглавље обухвата приказ коришћеног скупа података, његову припрему, поступак генерисања улазних слика које представљају полазну тачку реконструкције, као и генерисање референтних нормалних и дубинских мапа поступком ray casting, које служе као очекивани излаз прве фазе система. Одређивање очекиваних вредности SDF функције биће описано у поглављу о методологији.

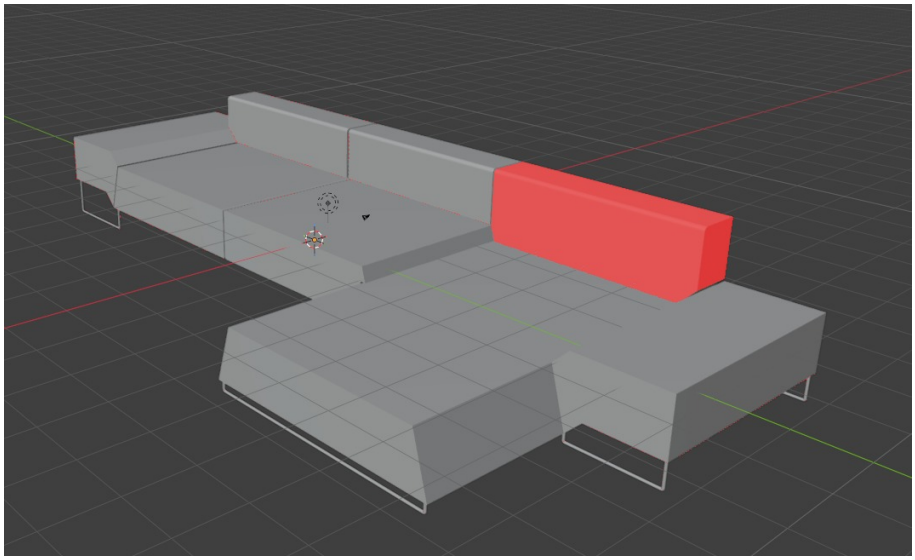
3.1 Избор скупа података

У раду је коришћен синтетички скуп података заснован на 3D моделима из скупа ModelNet40[3]. Из овог скупа одабрана је категорија *sofa*, јер обухвата објекте са јасном глобалном структуром, уочљивим ивицама и довољно разноврсном, али и даље контролисаном геометријом, што је чини погодном за анализу реконструкције у оквиру једне јасно дефинисане класе објеката. Категорија *sofa* садржи укупно 780 3D модела, а подела на тренинг и тест скуп преузета је директно из структуре припремљених фолдера. Тренинг скуп обухвата 680, а тест скуп 100 модела.

3.2 Припрема 3D модела

Оригинални модели из *sofa* категорије дати су као *.off* фајлови и нису директно прилагођени за даљу обраду у оквиру овог рада. Формат *.off* погодан је за геометријски запис модела и различите прорачуне над њиховом структуром, али у контексту реконструкције захтева додатну припрему.

С обзиром на то да нису првобитно припремани за директан рад у популарним алатима за обраду 3D модела, код дела примера уочене су некоректно оријентисане нормале. То се најлакше уочава при наношењу боја или текстура, јер се површине са погрешно усмереним нормалама тада приказују као да су окренуте ка унутрашњости модела, уместо ка његовој спољашњости. Иако таква грешка не мења драстично саму геометрију модела, нормале је било важно исправити како би рендеровање било у потпуности коректно.



Слика 8. Приказ погрешно оријентисаних нормала у програму Blender. Површине чије су нормале усмерене ка унутрашњости објекта приказане су црвеном бојом, док су исправно оријентисане површине сиве.

Припрема модела обухватала је њихову нормализацију, тако да буду центрирани око координатног почетка и скалирани на упоредив опсег, затим корекцију нормала, а потом и поједностављење геометрије, односно *low-poly* обраду.[5] Таквом припремом олакшана је обрада модела и смањена сложеност генерисања података, односно улазних слика.

3.3 Генерисање улазних слика

Уместо коришћења унапред фиксираног скупа рендерованих снимака, за потребе овог рада реализован је посебан модул за генерисање улазних слика. Овај модул за произвољан 3D модел, у било ком тренутку, генерише нове улазне примере на захтев, чиме је поступак прикупљања података потпуно одвојен од самог тренирања и лако се проширује на нове моделе или подешавања.

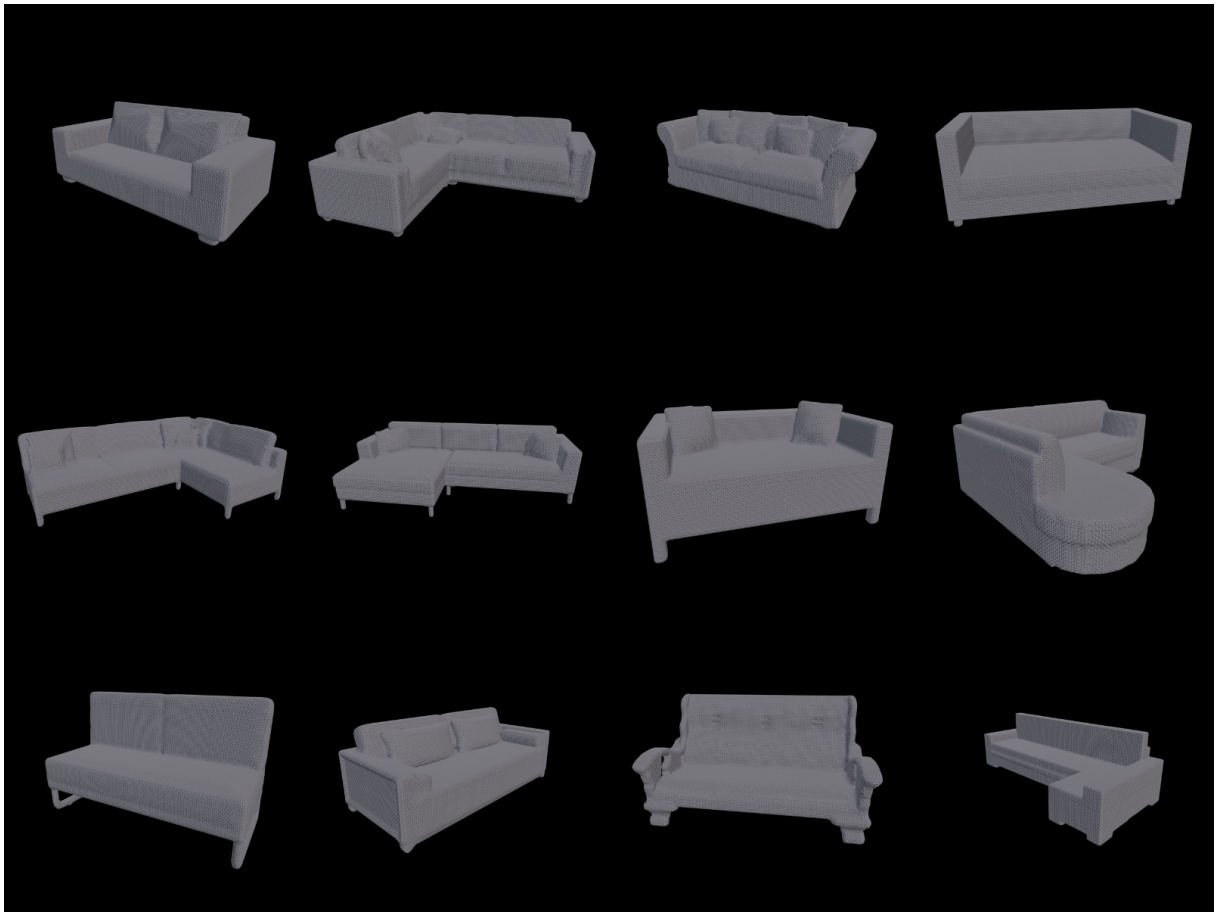
Модул за сваки пример бира један од 24 унапред дефинисана положаја камере, распоређена у фронталном угаоном опсегу од 120° око модела, тако да улазни скуп података покрива разноврсне, али контролисане углове посматрања објекта.

Независно од погледа, модул подржава и избор текстуре и боје модела, чиме се визуелни изглед улазне слике може мењати без утицаја на геометрију објекта. У овој верзији рада коришћена је једна фиксна текстура и боја за све моделе, како би анализа била усмерена искључиво на геометријску реконструкцију.

Сви примери се рендерују под истим, контролисаним условима, са фиксним осветљењем и транспарентном позадином, чиме се уклања утицај случајних варија-

[5] *Low-poly* обрада подразумева смањење броја полигона у 3D моделу. На тај начин модел постаје једноставнији за обраду, а основна геометријска структура остаје очувана.

ција у околини и обезбеђује да разлике међу сликама потичу искључиво од облика и погледа на модел. Добијене слике се потом скалирају на резолуцију 256×256 пиксела и чувају у PNG формату.

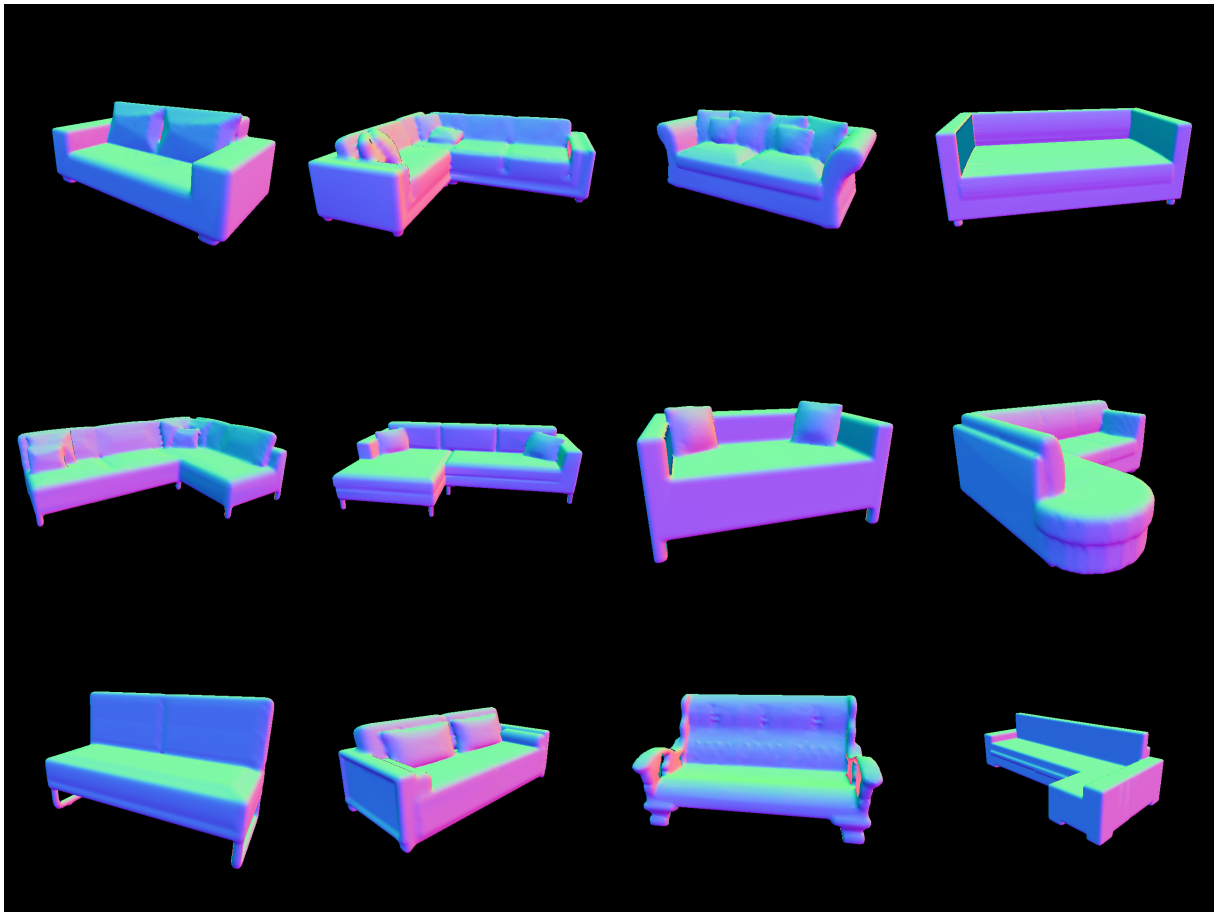


Слика 9. Дванаест примера улазних слика из скупа података.

3.4 Генерисање референтних нормалних мапа

Поред улазне RGB слике, за сваки пример генерише се и одговарајућа референтна нормална мапа, *ray casting* поступком. У тачки у којој зрак додирује површину 3D модела израчунава се њена оријентација, уз благо усредњавање са суседним тачкама (*smooth shading*), како би прелази између површина били глатки, а не изломљени.

Добијена оријентација записује се кроз три RGB канала. Свакој слици додаје се и четврти канал, који означава да ли пиксел припада објекту или прозирној позадини.

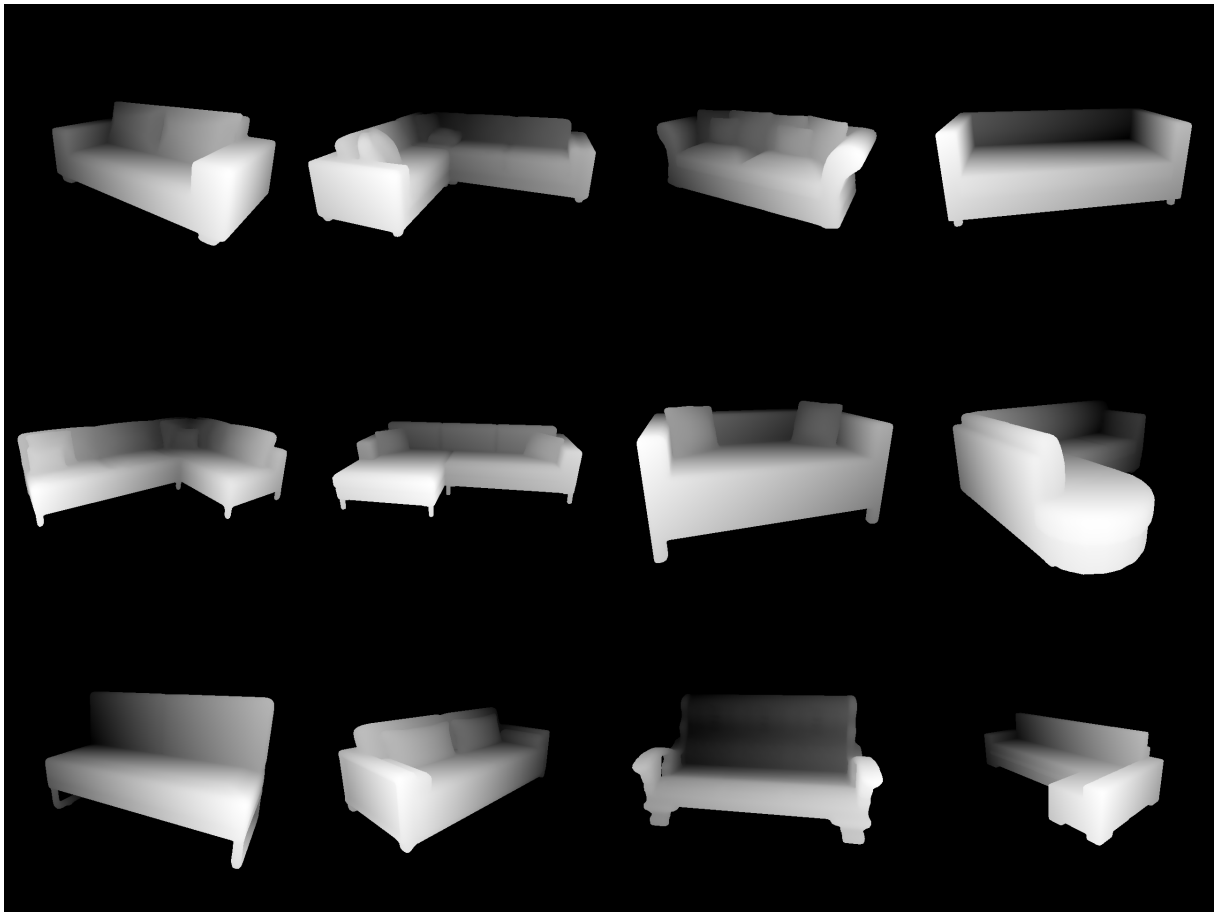


Слика 10. Дванаест примера генерисаних референтних нормалних мапа.

3.5 Генерисање референтних дубинских мапа

На исти начин, *ray casting* поступком, генерише се и референтна дубинска мапа, тако што се за сваки пиксел мери удаљеност тачке додира од камере.

За разлику од тросканалне нормалне мапе, излаз је овде слика са само једним каналом, при чему свака вредност представља измерену удаљеност тог пиксела од камере. Та удаљеност чува се као сива, 16-битна слика, уместо уобичајене 8-битне. Код 8-битне слике свака вредност сиве боје записује се једним бајтом, па може узети једну од 256 могућих нијанси, док 16-битни запис користи два бајта по пикселу и омогућава чак 65536 нијанси, чиме и мале разлике у дубини могу бити прецизно забележене. Позадина се, као и код нормалне мапе, посебно означава, чиме је јасно раздвојено који пиксели припадају објекту, а који су празан простор око њега.



Слика 11. Дванаест примера генерисаних референтних дубинских мапа.

3.6 Генерисање SDF узорака

За сваки модел генерише се скуп од 100.000 тачака у простору око објекта, које служе за учење SDF репрезентације облика. Већина (80%) добија се благим случајним померајем тачака узоркованих на површини, јер је тај уски појас уз површину најважнији за тачну реконструкцију облика. Остатак (20%) бира се насумично унутар кутије која обухвата модел, како би мрежа добила информацију и о простору даље од површине. Свакој тачки придружује се вредност SDF функције у тој тачки, која се чува уз њене координате.

4 Методологија рада

У овом поглављу описан је поступак реконструкције 3D облика који је реализован у оквиру рада. Систем је организован као низ јасно раздвојених корака. Најпре се из једне RGB слике предвиђају геометријске мапе, а затим се на основу њих формира латентни опис облика и реконструише коначан 3D mesh модел.

4.1 Преглед система

Цео поступак може се поделити на две повезане фазе. Прва фаза пресликава улазну RGB слику у две 2.5D репрезентације, нормалну и дубинску мапу. Друга фаза затим користи те мапе као основу за реконструкцију 3D облика у SDF репрезентацији, а потом и за издвајање коначног mesh модела применом Marching Cubes алгоритма.

Оваква организација омогућава да се сложен проблем подели на мање целине које се могу независно анализирати. На тај начин могуће је посебно испитати колико прва фаза тачно препознаје облик и ситне детаље површине на самој улазној слици, а затим и колико друга фаза, независно од тога, успешно гради комплетан 3D облик на основу добијених мапа.

4.2 Прва фаза (од 2D до 2.5D)

Прва фаза обухвата две одвојено обучаване U-Net мреже. Једна мрежа предвиђа нормалну мапу, а друга дубинску мапу. У оба случаја улаз је RGB слика резолуције 256×256, док је излаз мапа исте резолуције.

4.2.1 Предикција нормалне мапе

У наставку су описани архитектура мреже, припрема података, функција губитка и подела скупа уз аугментацију коришћени при обучавању мреже за предикцију нормалне мапе.

Архитектура мреже

За предикцију нормалне мапе коришћена је U-Net архитектура са четири нивоа енкодера и декодера и почетном ширином од 32 канала која се удвостручује на сваком наредном нивоу. Уместо batch нормализације коришћена је груписана нормализација (*Group Normalization*, осам група по слоју).[6] Прескочне везе очувавају

[6]Груписана нормализација дели канале сваког слоја на групе и нормализује их на основу статистике израчунате унутар једног примера, за разлику од batch нормализације која статистику рачуна преко целог batch-а примера.

фине просторне детаље, посебно важне на ивицама објекта и у областима нагле промене оријентације површине. Последњи слој мреже даје сирови излаз $\mathbf{o}(x)$, по једну вредност за сваку од три компоненте нормале, а над њим се затим примењује L_2 нормализација[7] која даје коначну предвиђену нормалу

$$\mathbf{n}^{pred} = \frac{\mathbf{o}(x)}{\|\mathbf{o}(x)\|_2}. \tag{14}$$

Овим се обезбеђује да је сваки предвиђени вектор јединичне дужине већ по конструкцији мреже.

Припрема података

Улазна RGB слика скалира се билинеарном интерполацијом.[8] За очекивану нормалну мапу билинеарна интерполација се не користи, јер би на ивицама, где се сусрећу две различито оријентисане површине, измешала њихове нормале и произвела вектор који не одговара стварној оријентацији ниједне од те две површине. Зато се нормална мапа скалира методом најближег суседа (*nearest neighbor*). После декодирања из RGB записа у опсег $[-1, 1]$, нормале се додатно нормализују ради уклањања грешке заокруживања, а вредности ван маске се поништавају.

Функција губитка

Функција губитка на пикселима објекта M комбинује косинусну компоненту између предвиђене нормале $\mathbf{n}_p^{pred}$ и референтне нормале $\mathbf{n}_p^{gt}$ у пикселу p са малом MSE компонентом,

$$\mathcal{L}_{nmap} = \frac{1}{|M|} \sum_{p \in M} \left(1 - \mathbf{n}_p^{pred} \cdot \mathbf{n}_p^{gt}\right) + 0{,}1 \cdot \frac{1}{|M|} \sum_{p \in M} \left\|\mathbf{n}_p^{pred} - \mathbf{n}_p^{gt}\right\|^2. \tag{15}$$

Косинусна компонента кажњава угаоно одступање, док MSE члан додатно наглашава исту грешку кроз стрмију, квадратну криву близу нуле, чиме убрзава и стабилизује конвергенцију.

Подела скупа и аугментација

Подела на тренинг, валидациони и тест скуп формира се по идентитету софе, а не по појединачним сликама, тако да различити погледи истог објекта не прелазе у више делова скупа, чиме валидација и тестирање проверавају генерализацију на невиђене облике, а не само невиђене погледе истог модела. Аугментација се примењује

[7] L_2 норма вектора, у ознаци $\|\cdot\|_2$, представља његову дужину, односно корен збира квадрата свих компоненти. Дељење вектора сопственом L_2 нормом даје вектор исте оријентације, али јединичне дужине.

[8] Билинеарна интерполација рачуна вредност пиксела као пондерисани просек четири најближа суседна пиксела, чиме благо умекшава прелазе.

само над RGB улазом, тако што се слика множи случајним фактором осветљења s, одсеца на опсег $[0, 1]$, а затим степенује случајним гама фактором g, при чему се s и g за сваки пример независно бирају из равномерне расподеле на интервалу [0,7, 1,3]. Тако се од оригиналне слике rgb добија измењена слика

$$\mathrm{rgb}' = \mathrm{clip}(\mathrm{rgb} \cdot s,\ 0,\ 1)^g, \qquad s, g \sim \mathcal{U}(0{,}7,\ 1{,}3). \tag{16}$$

Референтна нормална мапа при томе остаје непромењена, чиме модел учи да оријентацију површине процењује на основу облика и сенчења, а не конкретних вредности осветљења или материјала коришћених при рендеровању.

4.2.2 Предикција дубинске мапе

Обучавање мреже за предикцију дубинске мапе прати исти општи ток као код нормалне мапе, уз неколико специфичности које проистичу из скаларне природе дубине, описаних у наставку.

Архитектура мреже

За предикцију дубинске мапе коришћена је иста U-Net архитектура као и за нормалну мапу, само са једним излазним каналом $o(x)$, над којим се примењује сигмоидна функција $\sigma(\cdot)$,[9] чиме се добија дубина сведена на опсег $[0, 1]$

$$d_{norm}^{pred} = \sigma\big(o(x)\big) \in [0, 1]. \tag{17}$$

Као и L_2 нормализација код нормалне мапе, овим је излаз мреже одмах ограничен на дозвољени опсег. Предвиђена дубина се тек касније, помоћу задатих граница D_{near} и D_{far} (најближе и најдаље растојање у сцени), претвара у стварну удаљеност

$$d^{pred} = D_{near} + d_{norm}^{pred} \cdot (D_{far} - D_{near})\,. \tag{18}$$

Ово претварање се ради тек при рачунању метрика и чувању резултата, а само обучавање остаје у опсегу $[0, 1]$.

Припрема података

Улазна RGB слика скалира се, као и код нормалне мапе, билинеарном интерполацијом. Дубинска мапа се, из истог разлога као и нормална мапа, скалира методом најближег суседа. Дубина се потом декодира назад у опсег $[0, 1]$, а маска видљивог дела објекта одређује се из услова да кодирана вредност није једнака нули.

[9] Сигмоидна функција $\sigma(x) = 1/(1 + e^{-x})$ пресликава произвољну реалну вредност у интервал $[0, 1]$.

Функција губитка

Функција губитка на пикселима објекта M комбинује L_1 разлику предвиђене дубине d_p^{pred} и референтне дубине d_p^{gt} у пикселу p са малом MSE компонентом,

$$\mathcal{L}_{depth} = \frac{1}{|M|} \sum_{p \in M} \left| d_p^{pred} - d_p^{gt} \right| + 0{,}1 \cdot \frac{1}{|M|} \sum_{p \in M} \left(d_p^{pred} - d_p^{gt} \right)^2 . \tag{19}$$

Грешка се, као и код нормалних мапа, рачуна само над пикселима објекта. Главни члан је L_1 губитак, који боље подноси нагле промене дубине на силуети, док MSE члан додатно стабилизује градијент близу оптимума.

Подела скупа и аугментација

Подела скупа и аугментација исте су као код нормалне мапе, док и референтна дубинска мапа при аугментацији остаје непромењена. Тиме модел учи да дубину процењује на основу облика и просторног распореда видљивих делова, а не осветљења или материјала коришћених при рендеровању.

4.3 Друга фаза (од 2.5D до 3D)

Друга фаза обухвата учење заједничког простора облика из SDF узорака (Stage A), обучавање енкодера који из слике предвиђа латентни вектор у том простору (Stage B), и издвајање коначног mesh модела из наученог SDF поља.

4.3.1 Улаз друге фазе

Основна варијанта друге фазе спаја предвиђену нормалну мапу N (резолуције $H \times W$, три канала) и дубинску мапу D (један канал) по каналима, чиме настаје четвороканални улаз

$$X = [N, D] \in \mathbb{R}^{H \times W \times 4}. \tag{20}$$

Испробана је и варијанта само са нормалном мапом, као и варијанта само са полазном RGB сликом као улазом друге фазе. Код обе варијанте улаз је троканални. На овај начин, варијантом без издвајања дубинске мапе испитује се допринос дубинске информације, а варијантом без икаквих издвојених обележја испитује се допринос целог геометријског корака, односно прве фазе система.

4.3.2 Ауто-декодер и латентни простор (Stage A)

У Stage A систем учи заједнички простор облика искључиво на основу SDF узорака, без иједне слике. За разлику од уобичајеног аутоенкодера, овде не постоји енкодер који облик пресликава у латентни вектор, латентни вектори су слободни,

независни параметри које мрежа учи заједно са тежинама декодера. Пре почетка обучавања, сваком облику из тренинг скупа додељује се сопствени, насумично иницијализовани латентни вектор $z \in \mathbb{R}^{256}$, чуван у заједничкој табели латентних вектора, по један ред за сваки облик. Декодер D_ϕ учи да за дати латентни вектор z и произвољну тачку у простору x процени вредност SDF функције у тој тачки, $D_\phi(z, x) \approx \mathrm{SDF}(x)$. Обучавањем се декодер и латентни вектори заједно подешавају тако да сваки латентни вектор, провучен кроз декодер, верно описује облик коме припада.

Архитектура декодера

Декодер је вишеслојна потпуно повезана мрежа са осам слојева ширине 512, ReLU активацијом[10] и тежинском нормализацијом сваког слоја (*Weight Normalization*).[11] У сваком пролазу кроз мрежу, улаз чини спој $[z \,\|\, x]$, латентни вектор облика надовезан на координате тачке x за коју се тражи вредност SDF функције. На четвртом слоју се исти спој $[z \,\|\, x]$ поново додаје мрежи путем прескочне везе, тако да мрежа не мора да памти улаз кроз све претходне слојеве, чиме се олакшава учење финијих детаља облика. Излаз мреже је једна бројчана вредност, процењена вредност SDF функције у тачки x за облик z.

Функција губитка

За сваки облик из batch-а узоркује се скуп просторних тачака, при чему је однос тачака близу површине и тачака у ширем простору унапред одређен тако да се већина узорака нађе управо у уском појасу око површине, најважнијем за тачност реконструкције. За сваку узорковану тачку x рачуна се разлика између вредности коју процени декодер, $D_\phi(z, x)$, и стварне вредности SDF функције у тој тачки, $\mathrm{SDF}(x)$. Пре поређења се обе вредности одсецају (*clamp*) на опсег $[-\delta, \delta]$ (подразумевано $\delta = 0{,}1$), тако да свака вредност већа од δ или мања од $-\delta$ бива замењена најближом дозвољеном границом, δ односно $-\delta$. Тиме грешка далеко од површине, где тачна вредност SDF функције практично није битна за облик самог објекта, престаје да утиче на обучавање, па мрежа сав капацитет усмерава на тачно моделовање облика близу површине. Функција губитка тако гласи

$$\mathcal{L}_{sdf} = \left|\mathrm{clamp}(D_\phi(z, x), \delta) - \mathrm{clamp}(\mathrm{SDF}(x), \delta)\right|. \tag{21}$$

Ово је основни SDF губитак, изражен као L_1 разлика. Поред основног SDF губитка, на латентни вектор z додаје се и L_2 регуларизација, која га подстиче да остане близу

[10] ReLU (*Rectified Linear Unit*) је активациона функција облика $f(x) = \max(0, x)$, која негативне вредности своди на нулу, а позитивне пропушта непромењене.

[11] Тежинска нормализација раздваја тежине сваког слоја на правац и интензитет који се уче одвојено, чиме убрзава и стабилизује обучавање.

нуле и не одскочи предалеко од осталих латентних вектора. Тиме простор латентних вектора остаје компактан и гладак, а слични облици остају близу један другом, што касније олакшава енкодеру из Stage B да за нову слику пронађе одговарајући латентни вектор. Декодер и латентни вектори обучавају се различитим стопама учења, латентни вектори брже, јер описују само по један облик, док тежине декодера, заједничке за све облике, морају да се мењају опрезније.

4.3.3 Енкодер за предикцију латентног вектора (Stage B)

Ауто-декодер уме да опише само облике за које већ има научен латентни вектор, па за нове, невиђене софе не важи ниједан од тих вектора. Због тога је у Stage B обучен посебан енкодер, који из слике директно предвиђа одговарајући латентни вектор, док декодер и латентни вектори из Stage A остају непромењени.

Улазне варијанте

За сваку од 3 варијанте улаза, спој нормалне и дубинске мапе, само нормалну мапу и само полазни RGB рендер, обучен је по један засебан енкодер под истим протоколом. Коришћен је исти декодер и исти латентни вектори из Stage A, иста подела на тренинг и валидациони скуп, 200 епоха, batch 16, динамички избор погледа по епохи и додатни SDF губитак тежине 1,0.

Архитектура енкодера

Као енкодер користи се ResNet34, иницијализован ImageNet тежинама.[12] Када се уз нормалну користи и дубинска мапа, први слој се проширује на четири улазна канала, а тежине додатог канала иницијализују се средњом вредношћу постојећих RGB филтера, чиме се задржава корист иницијализације уз прихватање дубинске информације. Код преостала два режима број канала већ одговара стандардном ResNet стему, па се филтери преузимају без измене, иако код нормалне мапе улазне вредности одступају од природних RGB слика на којима је мрежа првобитно учена. Последњи, потпуно повезани слој даје вектор исте димензије као латентни простор из Stage A.

Функција губитка

Основни губитак мери квадрат Еуклидске норме растојања између предвиђеног $\hat{z}$ и наученог латентног вектора z_i из Stage A,

$$\mathcal{L}_{latent} = \|\hat{z} - z_i\|_2^2. \tag{22}$$

[12]ImageNet је велика, стандардна база милиона означених фотографија из свакодневног живота, коришћена за претходно обучавање (*pretraining*) многих мрежа за обраду слике, укључујући и ResNet.

Аугментација погледа

Важан детаљ Stage B обучавања је динамички избор погледа, за сваки приступ тренинг скупу бира се случајан поглед из задатог опсега уместо фиксног погледа по облику. Тиме се енкодер излаже већем броју визуелних варијација истог облика, боље генерализује и не учи напамет један конкретан поглед по софи.

4.3.4 Реконструкција mesh модела

Када енкодер предвиди латентни вектор, декодер за густу тродимензионалну мрежу тачака у нормализованом простору (типично резолуције 128^3) процени вредност SDF функције. Из тако добијеног скаларног поља Marching Cubes алгоритам директно гради коначан mesh модел, без додатног чишћења геометрије.

4.4 Ток обучавања

Обучавање прати структуру система. Најпре се припремају 3D модели и из њих генеришу RGB слике, референтне нормалне и дубинске мапе, као и SDF узорци. Затим се независно обучавају мреже за предикцију нормалних и дубинских мапа, потом Stage A ауто-декодер, а на крају Stage B енкодер, циљано на латентне векторе научене у Stage A. Овакав редослед је и концептуално важан, јер јасно раздваја део система који из слике извлачи геометрију видљиве површине од дела који моделује комплетан просторни облик.

4.5 Параметри обучавања

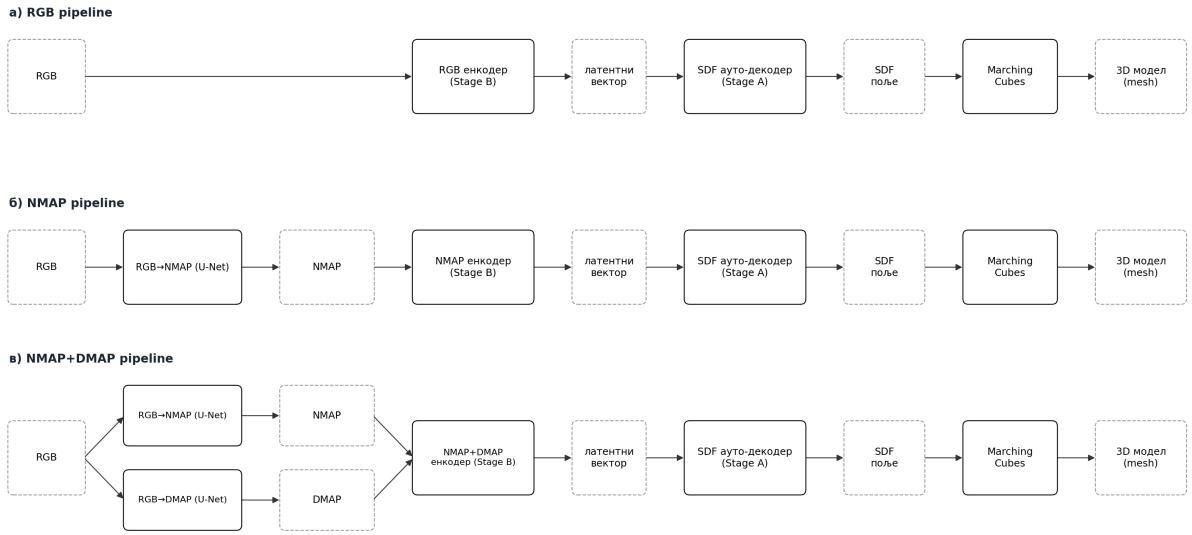
Подела на тренинг, валидациони и тест скуп врши се по идентитету софе, тако да исти 3D модел никада није истовремено у више делова скупа. Табела 1 сумира параметре свих шест модела система.

Модел	Тип	Улаз	Епохе	Batch	Филтери	Метрика
RGB→NMAP	U-Net (4 нивоа)	256×256×3	80	8	32 (база)	угаона грешка (°)
RGB→DMAP	U-Net (4 нивоа)	256×256×3	80	16	32 (база)	MAE, RMSE
SDF ауто-декодер	DeepSDF MLP (8×512, лат. 256)	SDF узорци	2000	32	—	одс. L_1, тач. знака
RGB енкодер	ResNet34 (лат. 256)	256×256×3	200	16	64 (стем)	MSE лат., тач. знака
NMAP енкодер	ResNet34 (лат. 256)	256×256×3	200	16	64 (стем)	MSE лат., тач. знака
NMAP+DMAP енкодер	ResNet34 (лат. 256)	256×256×4	200	16	64 (стем)	MSE лат., тач. знака

Табела 1. Архитектура и параметри обучавања свих модела у систему. U-Net модели користе AdamW оптимизатор и косинусно опадање стопе учења.

4.6 Реконструкција 3D модела

Систем подржава три потпуна *pipeline*-а од RGB слике до 3D mesh-а, који се разликују искључиво по улазу у Stage B енкодер. Реконструкција се у свим случајевима добија једним пролазом кроз мрежу, без накнадне оптимизације. Stage A декодер и Marching Cubes корак идентични су у сва три pipeline-а, док се прва два корака разликују по улазном режиму (Слика 12).



Слика 12. Три pipeline-а за реконструкцију 3D модела од RGB слике до mesh-а (RGB, NMAP и NMAP+DMAP).

4.7 Имплементација

Цео рад, укључујући припрему 3D модела, обучавање мрежа, реконструкцију и обраду и визуализацију резултата, имплементиран је у програмском језику Python и представљен кроз Jupyter Notebook. Коришћене су и следеће Python библиотеке:

numpy (нумерички рачун и рад с низовима у свим фазама, процедурално генерисање текстура)

trimesh (ray casting за генерисање нормалних и дубинских мапа, узорковање SDF тачака)

point-cloud-utils (pcu) (поправка water-tight геометрије при конверзији .off у .obj)

embreex (убрзање ray casting-а односно BVH који притом користи trimesh)

pyrender (рендеровање RGB слика софа)

pillow (pil) (читање и писање PNG слика)

pytorch (torch) (дефиниција и обучавање неуронских мрежа)

torchvision (претренирани ResNet тежине са ImageNet-а за иницијализацију Stage B енкодера)

scipy (Chamfer растојање преко `cKDTree` претраге најближег суседа)

scikit-image (Marching Cubes екстракција нулте изоповршине, односно mesh-а, из предвиђеног SDF поља)

matplotlib (исцртавање графика)

tqdm (приказ напретка, *progress bar*, током тренинга)

open3d (опциони преглед реконструисаног mesh-а)

У изради имплементације коришћени су и AI алати, конкретно ChatGPT и Claude, за генерисање и разраду идеја, за писање кода (*vibe coding*), за обраду и визуализацију резултата, као и за рефакторисање постојећег кода.

5 Резултати

У овом поглављу приказани су резултати за поједине кораке система реализованог у раду.

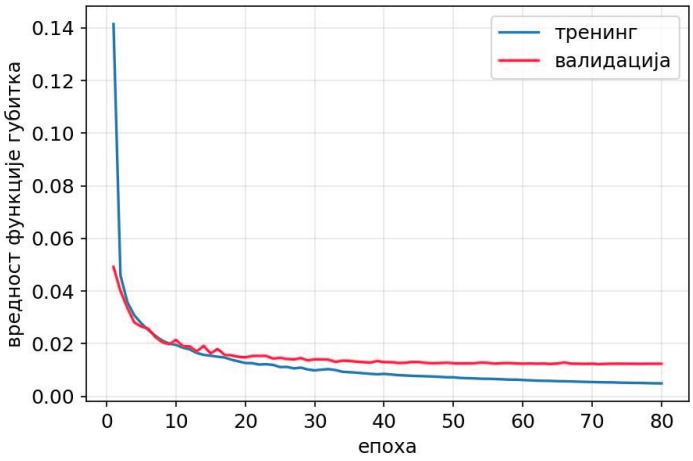
5.1 Резултати предикције нормалних мапа

Мрежа за предикцију нормалне мапе обучавана је 80 епоха. Средња угаона грешка, која показује колико се предвиђена нормала по правцу разликује од стварне, опада са почетних 12,09° на свега 4,35° до краја обучавања (Табела 2). На тест скупу, са невиђеним облицима, грешка износи 4,63°, што је веома близу резултату на обучавању и показује добру генерализацију.

Епоха	Тренинг губитак	Вал. губитак	Тренинг грешка	Вал. грешка
1	0,1414	0,0492	21,92°	12,09°
10	0,0196	0,0214	6,56°	6,76°
20	0,0127	0,0148	4,99°	5,19°
40	0,0086	0,0130	3,93°	4,62°
60	0,0062	0,0124	3,24°	4,41°
80	0,0049	0,0124	2,86°	4,35°

Табела 2. Ток обучавања мреже за предикцију нормалне мапе кроз изабране епохе.

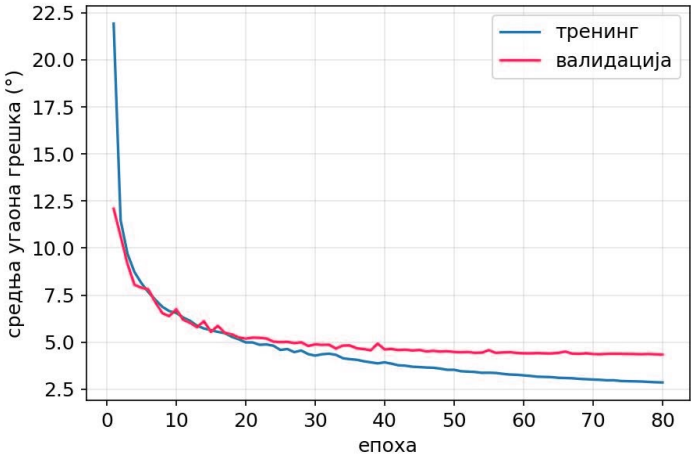
Исти ток обучавања приказан је и графички, кроз криве губитка (Слика 13) и угаоне грешке (Слика 14).



Слика 13. Вредност функције губитка на тренинг и валидационом скупу кроз епохе, за предикцију нормалне мапе.

Обе криве нагло опадају у првих двадесетак епоха, а затим све спорије. Ра-

злика тренинг и валидационе криве остаје умерена, без знакова агресивног преобучавања.



Слика 14. Средња угаона грешка на тренинг и валидационом скупу кроз епохе, за предикцију нормалне мапе.

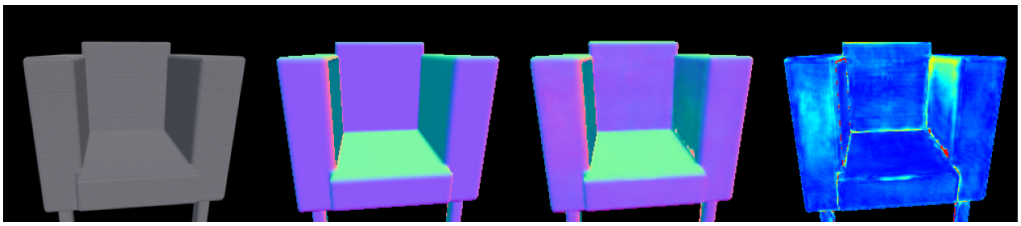
Крива угаоне грешке прати исти образац, брзо опада, а затим се стабилизује након отприлике 40. епохе, у складу са вредностима из Табеле 2.

На тест скупу, 93,41% пиксела има грешку мању од 11,25°, а чак 99,05% мању од 30°. Медијана грешке је нешто нижа од просека, што значи да мали број тежих пиксела, углавном на ивицама објекта, повлачи просек навише (Слика 15).

Скуп	Средња угаона грешка	Медијана
Валидација (најбоља епоха)	4,35°	2,63°
Тест	4,63°	2,76°

Табела 3. Резултати предикције нормалних мапа (угаона грешка).

Визуелно, модел добро предвиђа нормале на већим, равним површинама софе, док су грешке највеће на ивицама и танким деловима. У целини, предвиђене нормалне мапе веома блиско прате мапе добијене директно из 3D геометрије објекта.



Слика 15. Пример предикције нормалне мапе. Колоне су, редом, улазна слика, очекивана нормална мапа, добијена нормална мапа и топлотна мапа грешке у односу на очекивану мапу.

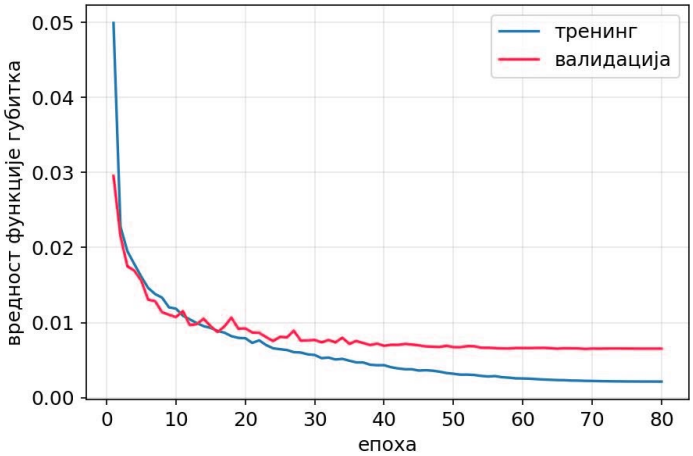
5.2 Резултати предикције дубинских мапа

Тачност предикције дубине мери се преко MAE, средње апсолутне грешке. Грешка на валидационом скупу опада на 0,0146 до 69. епохе, а затим остаје стабилна, док тренинг MAE наставља да опада све до 0,0047 (Табела 4). Ова разлика указује на благо преобучавање, модел на тренинг подацима постаје тачнији него на валидационим, али разлика остаје мала.

Епоха	Тренинг губитак	Вал. губитак	Тренинг MAE	Вал. MAE	Вал. RMSE
1	0,0499	0,0296	0,1086	0,0651	0,0846
10	0,0119	0,0107	0,0260	0,0241	0,0345
20	0,0079	0,0092	0,0174	0,0206	0,0292
40	0,0043	0,0069	0,0095	0,0155	0,0232
60	0,0026	0,0066	0,0056	0,0148	0,0224
69	0,0023	0,0065	0,0049	0,0146	0,0220
80	0,0021	0,0065	0,0047	0,0147	0,0222

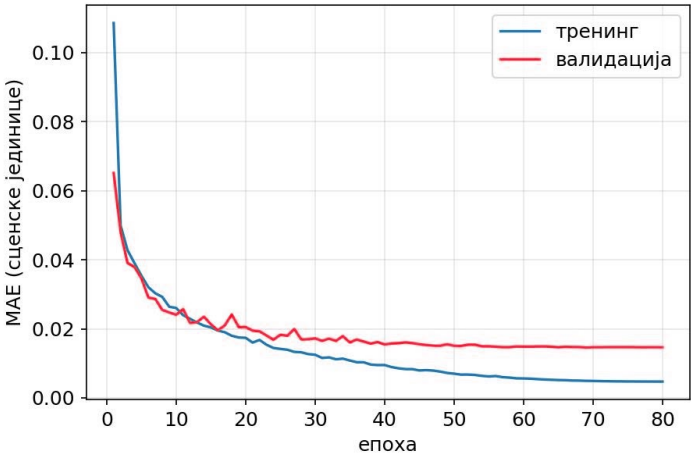
Табела 4. Ток обучавања мреже за предикцију дубинске мапе кроз изабране епохе (MAE и RMSE изражени у сценским јединицама).

Исти ток обучавања приказан је и графички, кроз криве губитка (Слика 16) и MAE грешке (Слика 17).



Слика 16. Вредност функције губитка на тренинг и валидационом скупу кроз епохе, за предикцију дубинске мапе.

Обе криве нагло опадају у почетним епохама, а затим се стабилизују. Валидациона крива се практично изравнава већ после 40–50. епохе.



Слика 17. Средња апсолутна грешка (MAE) на тренинг и валидационом скупу кроз епохе, за предикцију дубинске мапе.

Тренинг крива наставља благо да опада до краја обучавања, док се валидациона крива рано стабилизује и остаје готово непромењена, исти образац благог преобучавања примећен и код губитка.

На тест скупу, који садржи 445 примера, добијен је MAE од 0,0196 и RMSE од 0,0362, уз медијану грешке од свега 0,0104.

Скуп	MAE	RMSE
Валидација (најбоља епоха)	0,0146	0,0220
Тест	0,0196	0,0362

Табела 5. Резултати предикције дубинских мапа.

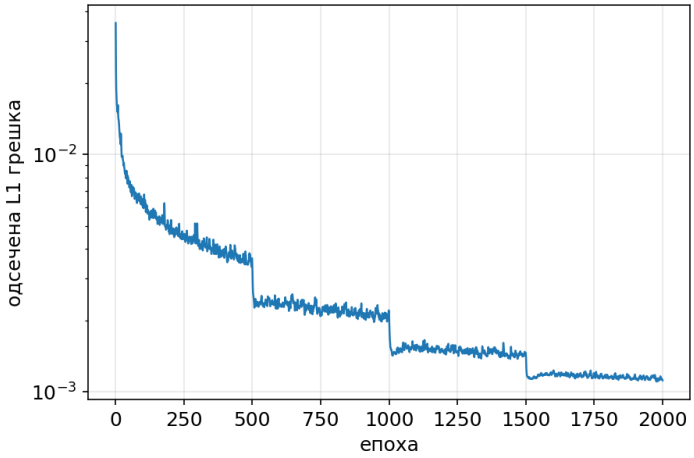
Визуелно, предвиђене дубинске мапе добро прате општи облик софе, а грешке су највеће на ивицама и на местима нагле промене дубине (Слика 18). У целини, предвиђене мапе веома блиско прате мапе добијене директно из 3D геометрије.



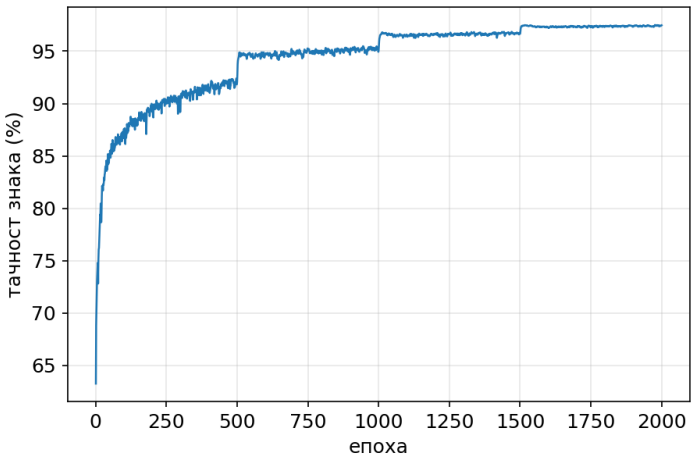
Слика 18. Пример предикције дубинске мапе. Колоне су, редом, улазна слика, очекивана дубинска мапа, добијена дубинска мапа и топлотна мапа грешке у односу на очекивану мапу.

5.3 Резултати обучавања ауто-декодера (Stage A)

У Stage A се обучавање изводи искључиво над облицима из тренинг скупа, без слика и без потребе за генерализацијом на невиђене облике, па овде не постоји валидациони скуп. Сваком облику додељен је сопствени латентни вектор, а декодер учи да из тог вектора и координата произвољне тачке процени вредност SDF функције у њој.



Слика 19. Одсечена L_1 грешка ауто-декодера кроз епохе (логаритамска размера).



Слика 20. Тачност знака ауто-декодера кроз епохе.

Скокови на 500., 1000. и 1500. епохи потичу од преполовљавања стопе учења.

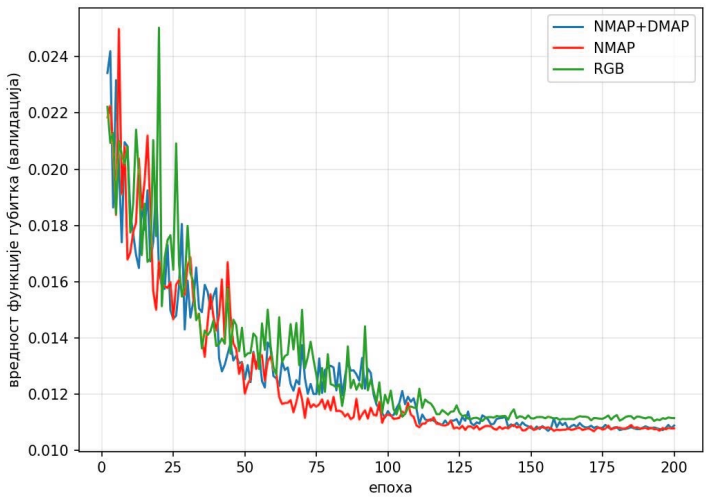
Епоха	Одсечена L_1 грешка	Тачност знака
1	0,0357	63,3%
50	0,0076	85,0%
100	0,0060	87,6%
400	0,0039	91,3%
800	0,0022	95,0%
1200	0,0015	96,6%
1600	0,0012	97,2%
1979 (најбоља)	0,0011	97,5%
2000 (последња)	0,0011	97,5%

Табела 6. Ток обучавања ауто-декодера кроз изабране епохе.

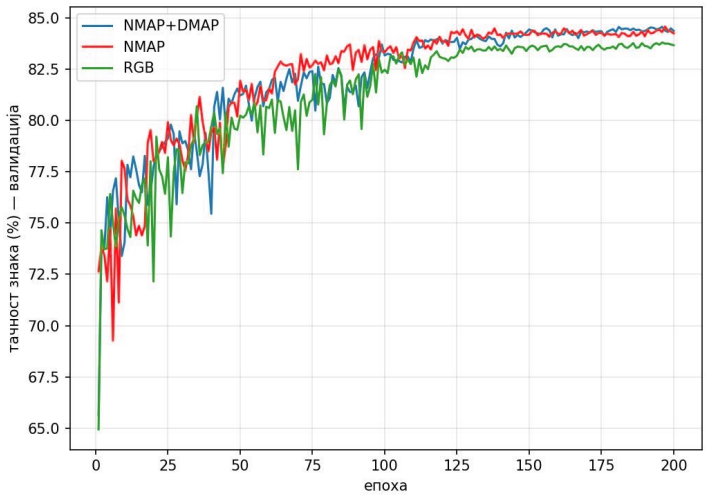
Тачност знака, односно да ли декодер тачно одреди да ли је тачка унутар или изван облика, расте до прага од 97,5%, без знакова преобучавања. Декодер добро репродукује тренинг облике.

5.4 Резултати обучавања енкодера (Stage B)

У Stage B обучава се енкодер који из улазне слике директно предвиђа латентни вектор облика, уз декодер и латентне векторе научене у Stage A. За разлику од Stage A, овде постоји посебан валидациони скуп са невиђеним облицима, па тачност на њему представља праву меру генерализације модела. Под истим протоколом обучена су три засебна енкодера, који се међусобно разликују само по улазу (NMAP+DMAP, NMAP или RGB).



Слика 21. Вредност функције губитка на валидационом скупу кроз епохе, за сва три улазна режима енкодера.



Слика 22. Тачност знака на валидационом скупу кроз епохе, за сва три улазна режима енкодера.

Улазни режим	Најбоља еп.	Вал. губитак	Вал. тачност	Тренинг тачност
NMAP+DMAP	156	0,0107	84,5%	92,2%
NMAP	172	0,0107	84,4%	91,3%
RGB	193	0,0111	83,7%	91,1%

Табела 7. Резултати три обучена енкодера по улазном режиму, губитак и тачност знака на валидационом скупу у најбољој епохи, и тачност знака на тренинг скупу у последњој (200.) епохи.

Сва три енкодера показују сличан ток обучавања, са стабилизацијом између 150. и 200. епохе (Табела 7). Варијанте засноване на нормалној мапи, самостално или уз дубинску, благо, али доследно надмашују RGB варијанту (84,4 – 84,5% наспрам 83,7% тачности знака на валидацији), док је разлика између NMAP и NMAP+DMAP занемарљива, што показује да дубинска мапа овде не доноси велики додатни допринос. Ипак, сва три модела остају прилично близу једно другом и знатно испод тачности коју декодер постиже над директно наученим латентним векторима из Stage A (преко 97%). То показује да је регресија латента из слике, без обзира на улазни режим, највеће уско грло целог система.

5.5 Финална 3D реконструкција

Финална реконструкција не укључује никакву додатну оптимизацију у тесту, латентни вектор се предвиђа једним пролазом кроз енкодер и одмах декодира, без накнадне корекције. За сваки од три улазна режима постоји потпун *pipeline* који иде директно од RGB слике до mesh-а. У RGB pipeline-у слика се директно прослеђује

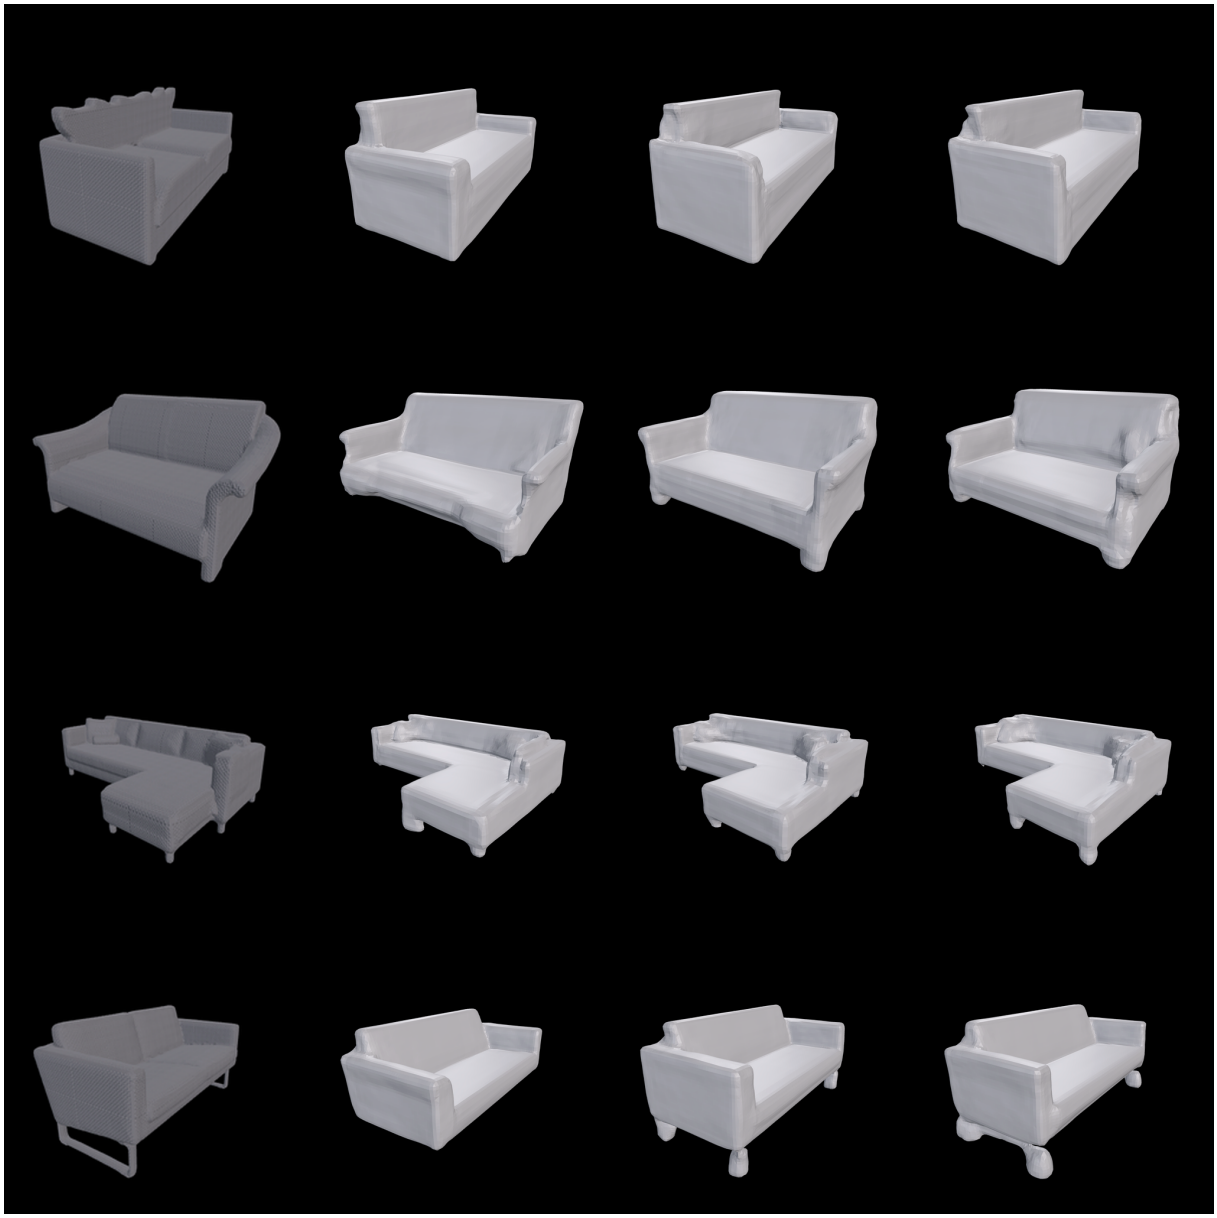
RGB енкодеру. У NMAP и NMAP+DMAP pipeline-има, прва фаза, односно стварни, обучени U-Net модели, а не референтне мапе из скупа података, најпре предвиђа нормалну, или нормалну и дубинску мапу заједно. Тек тако добијена мапа прослеђује се одговарајућем енкодеру. У сва три случаја, добијени латентни вектор потом декодира Stage A декодер, а Marching Cubes алгоритам (резолуција 128^3) из добијеног SDF поља гради коначан mesh.

Квалитет реконструкције мерен је Chamfer растојањем у односу на референтни mesh, на 100 невиђених софа из тест скупа.

Pipeline	Просек Chamfer	Медијана Chamfer
RGB	0,0310	0,0242
NMAP	0,0328	0,0260
NMAP+DMAP	0,0324	0,0259

Табела 8. Chamfer растојање финалне реконструкције (RGB → mesh) на 100 невиђених софа из тест скупа, по pipeline-у.

Сва три pipeline-а дају визуелно врло сличне, употребљиве реконструкције (Слика 23), а и нумерички су веома блиски (Табела 8). Ипак, RGB pipeline благо, али доследно надмашује оба pipeline-а која користе геометријске мапе, иако су NMAP и NMAP+DMAP енкодери сами по себи тачнији у процени латента, како је показано у претходном одељку. Разлог је у томе што ова, крајња оцена користи мапе које предвиђа прва фаза, а не тачне референтне мапе. NMAP и NMAP+DMAP pipeline-и тако носе и грешку прве фазе, док је RGB pipeline нема, јер иде директно из фотографије, без икаквог посредног корака.



Слика 23. Четири примера реконструкције. С лева на десно у сваком реду, улазна RGB слика и реконструкције RGB, NMAP и NMAP+DMAP pipeline-а, рендероване из истог погледа.

5.6 Упоредна анализа

Поређење различитих улазних режима даје два наизглед супротна резултата, у зависности од тога на ком нивоу се мери. На нивоу самог енкодера (Табела 7), обучаваног и валидираног на тачним мапама, NMAP и NMAP+DMAP благо надмашују RGB, јер чиста геометријска репрезентација олакшава регресију латента. На нивоу целог pipeline-а (Табела 8), где ове мапе тек треба да предвиди прва фаза, поредак се обрне, RGB pipeline даје незнатно бољу крајњу реконструкцију.

Разлика између NMAP и NMAP+DMAP остаје занемарљива у оба поређе-

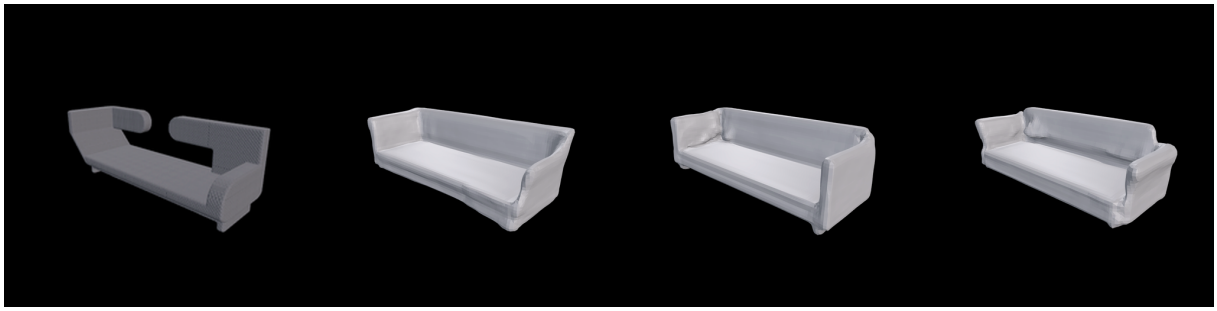
ња, што указује да сама дубинска мапа, у овој поставци, не доноси велики додатни допринос преко нормалне мапе.

5.7 Анализа неуспешних примера

Поред успешних резултата, важно је размотрити и случајеве у којима реконструкција није задовољавајућа, јер они показују главне изворе грешке система.

Софе необичног облика

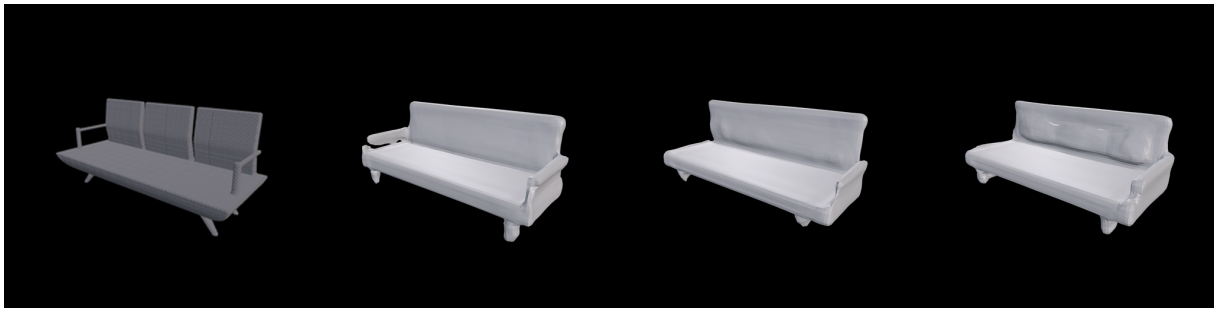
Слика 24 приказује софу асиметричног облика, са наслонима различите висине и отвореним средишњим делом. Сва три pipeline-а реконструишу генеричан, симетричан облик софе, потпуно губећи ту карактеристичну асиметрију.



Слика 24. Неуспешна реконструкција необичног облика софе. С лева на десно, RGB слика и реконструкције RGB, NMAP и NMAP+DMAP pipeline-а.

Губитак ситних детаља

Слика 25 приказује клупу-софу са три јасно одвојена сегмента наслона, танким ногицама и наслоном за руку. Све три реконструкције добро задржавају општи облик тела, али подела наслона на сегменте нестаје у једну глатку површину, ногице се своде на једва видљиве остатке, а наслон за руку скоро у потпуности ишчезава.



Слика 25. Губитак ситних детаља при реконструкцији. С лева на десно, RGB слика и реконструкције RGB, NMAP и NMAP+DMAP pipeline-а.

Узроци обе врсте грешке, и могући правци њихове исправке, разматрани су у наредном поглављу.

6 Дискусија

Резултати показују да прорачун нормалних и дубинских мапа не доноси мерљив допринос крајњем квалитету 3D реконструкције, иако су ти модели технички тачни. Поређење три потпуна pipeline-а показује да RGB pipeline, који латентни вектор предвиђа директно из RGB слике без рачунања геометријских мапа, постиже исти, чак благо бољи резултат од NMAP и NMAP+DMAP pipeline-а. Другим речима, готово идентична реконструкција добија се директно из RGB слике, без икаквог посредног геометријског корака.

Ово је на први поглед неочекивано, јер нормална и дубинска мапа теоријски уклањају текстуру, боју и материјал као сметњу и енкодеру остављају „чисту“ геометријску информацију. Тај ефекат делимично и постоји, у изолованој евалуацији енкодера NMAP и NMAP+DMAP благо надмашују RGB по тачности знака. Та предност је ипак мала, а грешка коју у пун pipeline уноси предикција мапа у првој фази није занемарљива, па се када се обе ствари споје предност геометријске репрезентације изгуби.

Практична последица тога јесте да двофазна архитектура, колико год концептуално привлачна, у оваквом облику не оправдава своју сложеност. Регресија латентног вектора директно из RGB слике сама по себи носи скоро сву информацију доступну из једне слике, док посредно рачунање нормалне и дубинске мапе додаје два додатна модела, дуже тренирање, и додатни извор грешке, без стварне користи за крајњи резултат.

Ако се резултати пореде појединачно по фазама, показује се да прва фаза сама по себи веома успешно предвиђа нормалне и дубинске мапе из улазне RGB слике, па сама предикција геометријских мапа није проблем. Проблем је што се та тачна предикција не преноси у бољу 3D реконструкцију. Два узастопна, добро обучена модела, U-Net за мапу и ResNet енкодер за латент, уносе сопствену грешку у сваком кораку, а та кумулативна грешка поништава предност коју геометријска репрезентација има над сировом RGB сликом. Могуће објашњење зашто RGB режим уопште држи корак са NMAP и NMAP+DMAP режимима лежи у самој иницијализацији ResNet енкодера. Тежине су претходно научене на ImageNet скупу, који се готово у потпуности састоји од реалних фотографија. Таква иницијализација се највише поклапа са RGB рендерима софе, који по изгледу личе на природне фотографије на којима је мрежа првобитно учена, док су нормалне и дубинске мапе визуелно апстрактне и удаљеније од тог распореда. Ако је ова претпоставка тачна, предност коју RGB режим показује делом не потиче од саме репрезентације, већ од тога колико улазна слика личи на податке на којима је енкодер претходно учен.

Гледано с друге стране, прва фаза не игра значајну улогу у крајњем резултату, па фокус треба пребацити на другу фазу, пре свега на то зашто код неких софа долази

до лоших резултата и на покушај да се ти недостаци исправе. Регресија латентног вектора, независно од улазног режима, представља уско грло система. Stage A ауто-декодер при томе формира простор у коме су различите софе представљене као уређени латентни вектори, довољно добар да реконструкција остане смислена и када енкодер не погоди тачан латент, тако да грешка коју уочавамо готово увек потиче од саме регресије латента, а не од декодера. Извори те грешке нису исти код свих примера, већ се могу сврстати у неколико група. Ако се са саме перспективе улазне слике неки део објекта не види добро, грешка је очекивана и не потиче од самог модела, већ од недостатка информације у улазу, а такав недостатак може се решити једино увођењем више погледа истог објекта, док се реконструкцијом из једне слике системски не може отклонити ни на који начин. Преостале две групе грешака односе се на софе необичног облика и на губитак ситних детаља, код којих узрок грешке и правце исправке можемо директно анализирати.

6.1 Узроци неуспешних примера

Софе необичног облика

До ове грешке долази јер Stage A ауто-декодер учи заједнички латентни простор на основу учесталости облика у тренинг скупу, па ретки облици леже на ободу тог простора, где је декодер мање поуздан. Енкодер се додатно ослања на само један, двосмислен поглед, па необичну софу повлачи ка доминантном, типичном облику из тренинг скупа. Могући правци исправке су пондерисано узорковање тренинг скупа које даје већи утицај атипичним облицима, већи латентни простор са слабијом L_2 регуларизацијом, и јаче ослањање на SDF губитак приликом регресије латента.

Губитак ситних детаља

Овај губитак потиче делом из саме функције губитка. Одсечена L_1 SDF грешка усредњава се по узоркованим тачкама, а танке структуре попут ногица и наслона за руку заузимају занемарљив део укупне површине софе, па их модел током обучавања лако „изгладиˮ у корист тачнијег описивања доминантног тела. Резолуција Marching Cubes мреже додатно ограничава колико фине геометрије уопште могу бити представљене. Могући правци исправке су циљано узорковање SDF тачака око танких структура, виша резолуција Marching Cubes мреже и већи капацитет декодера.

6.2 Ограничења и правци даљег рада

Ограничења разматране методе проистичу пре свега из саме поставке задатка. Систем је обучаван на синтетичким подацима, ограничен је на једну класу објеката и ослања се на један поглед. Због тога треба бити опрезан при процени колико се

добијени резултати могу пренети на реалне фотографије и на шири скуп објеката.

На основу свега изложеног, најважнији правци даљег рада су:

Поједностављење pipeline-а

RGB pipeline даје исти или бољи резултат од NMAP/NMAP+DMAP pipeline-а уз мању сложеност, па је логичан следећи корак да се развојни напор усмери директно на RGB → латент регресију, а не на даљу предикцију геометријских мапа. Прва фаза (U-Net мреже) остаје корисна за визуелну интерпретацију и анализу грешке, али не мора бити део коначног pipeline-а.

Јачи енкодер

Регресија латента, независно од улазног режима, остаје главно уско грло система, па вреди испитати дубље или шире backbone архитектуре, дужи тренинг и агресивнију аугментацију, као и веће и разноврсније тренинг скупове.

Циљано решавање два уочена типа грешке

Пондерисано узорковање и већи капацитет латентног простора за нетипичне облике, као и адаптивно, циљано узорковање SDF тачака и виша резолуција Marching Cubes мреже за очување ситних детаља.

Вишепогледни улаз

Велики део грешака потиче од двосмислености једног погледа (заклоњени делови, необичан облик), па је природно проширење да систем прими два или више погледа исте софе и обогати латентни вектор информацијом коју ниједан појединачни поглед сам не носи.

Провера на реалним фотографијама

RGB pipeline је и најједноставнији и, по резултатима, подједнако добар, па најважније следеће питање више није „да ли геометријске мапе помажу“, већ колико добро директна RGB → латент регресија генерализује изван синтетичког домена. Тестирање на реалним фотографијама софа, ван контролисаних услова рендеровања, требало би да буде приоритет пре даљег усавршавања архитектуре.

7 Закључак

У овом дипломском раду разматран је проблем реконструкције тродимензионалног облика софе на основу једне RGB слике. Реализован је потпун поступак који обухвата припрему синтетичког скупа података, генерисање нормалних и дубинских мапа, учење простора 3D облика у SDF репрезентацији, регресију латентног вектора из слике и коначно издвајање mesh модела.

Кључна идеја рада била је да се сложен проблем не решава директно једним моделом, већ да се подели на две повезане фазе. У првој фази систем из RGB слике издваја геометријски релевантне мапе, а у другој фази из тих мапа реконструише 3D облик. Оваква организација показала се корисном за праћење међурезултата и анализу извора грешке, иако се, поређењем три потпуна pipeline-а, испоставило да сам геометријски међукорак не доноси мерљиву предност у односу на директну регресију латента из RGB слике.

Учење предикције нормалних и дубинских мапа, упркос уложеном труду и техничкој тачности тих модела, на крају није донело стваран допринос квалитету финалне 3D реконструкције, јер RGB pipeline сам по себи даје исти резултат. Ипак, кроз рад на овом делу система обрађен је низ концепата из рачунарске графике и дубоког учења, попут бацања зрака (ray casting), Bounding Volume Hierarchy (BVH) структура коришћених за убрзање тог поступка и U-Net архитектуре. Разумевање ових концепата представља вредан резултат рада, независно од коначног доприноса тих компоненти крајњој реконструкцији.

Значајан део имплементације и анализе резултата настао је уз помоћ AI алата попут ChatGPT-а и Claude-а. Њихова употреба показала се корисном за убрзање рада, генерисање идеја и рефакторисање кода, али су предлози AI алата врло често водили у погрешном правцу или почивали на решењима која нису заснована на стварном разумевању проблема. Због тога је било неопходно да се, пре примене било које AI идеје, детаљно проучи стручна литература и да се према предлозима AI алата задржи критички однос, уз потпуну контролу аутора над целим процесом израде рада.

Резултати рада јесу добри, али добијени 3D модели не угрожавају радно место ниједног професионалног 3D дизајнера :)

8 Литература

[1] K. Sakai and Y. Yasumura, "Three-Dimensional Shape Reconstruction from a Single Image by Deep Learning," 2020.

[2] O. Ronneberger, P. Fischer and T. Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation," in *Medical Image Computing and Computer-Assisted Intervention*, 2015.

[3] Z. Wu, S. Song, A. Khosla, F. Yu, L. Zhang, X. Tang and J. Xiao, "3D ShapeNets: A Deep Representation for Volumetric Shapes," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2015. Доступно на: `https://openaccess.thecvf.com/content_cvpr_2015/html/Wu_3D_ShapeNets_A_2015_CVPR_paper.html`. Dataset webpage: `https://modelnet.cs.princeton.edu/download.html`.

[4] K. He, X. Zhang, S. Ren and J. Sun, "Deep Residual Learning for Image Recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016.

[5] P. Isola, J.-Y. Zhu, T. Zhou and A. A. Efros, "Image-to-Image Translation with Conditional Adversarial Networks," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2017.

[6] J. J. Park, P. Florence, J. Straub, R. Newcombe and S. Lovegrove, "DeepSDF: Learning Continuous Signed Distance Functions for Shape Representation," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2019.

[7] C. B. Choy, D. Xu, J. Gwak, K. Chen and S. Savarese, "3D-R2N2: A Unified Approach for Single and Multi-view 3D Object Reconstruction," in *Proceedings of the European Conference on Computer Vision*, 2016.

[8] H. Fan, H. Su and L. J. Guibas, "A Point Set Generation Network for 3D Object Reconstruction from a Single Image," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2017.

[9] W. E. Lorensen and H. E. Cline, "Marching Cubes: A High Resolution 3D Surface Construction Algorithm," in *Proceedings of SIGGRAPH*, 1987.

[10] A. Appel, "Some Techniques for Shading Machine Renderings of Solids," in *Proceedings of the Spring Joint Computer Conference*, 1968.

[11] T. L. Kay and J. T. Kajiya, "Ray Tracing Complex Scenes," in *Proceedings of SIGGRAPH*, 1986.

[12] H. G. Barrow, J. M. Tenenbaum, R. C. Bolles and H. C. Wolf, "Parametric Correspondence and Chamfer Matching: Two New Techniques for Image Matching," in *Proceedings of the 5th International Joint Conference on Artificial Intelligence*, 1977.

[13] X. Wang, S. Gao, M. Wang and Z. Duan, "A Marching Cube Algorithm Based on Edge Growth," *arXiv preprint arXiv:2101.00631*, 2021. Доступно на: `https://arxiv.org/abs/2101.00631`.